TRƯỜNG ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH
**KHOA CÔNG NGHỆ THÔNG TIN**

---ꕥ 🕮 ꕥ---

**TIỂU LUẬN MÔN HỌC**

# TRÍ TUỆ NHÂN TẠO

# Đề tài

## DỰ ĐOÁN KHẢ NĂNG SỐNG SÓT CỦA HÀNH KHÁCH TÀU TITANC

**Lớp: DH23IT01**
**Giảng viên hướng dẫn: Thầy Võ Việt Khoa**



| MSSV | Họ tên |
|---|---|
| Diệp Bảo Doanh | 2251050018 |
| Phạm Hoàng Phú Quý | 2351050148 |
| Lê Thanh Hiếu | 2354120032 |
| Nguyễn Trường Bách | 2351050010 |

# TÓM TẮT:

Báo cáo trình bày toàn bộ quy trình xây dựng hệ thống dự đoán khả năng sống sót của hành khách tàu Titanic – một bài toán phân loại nhị phân kinh điển trong lĩnh vực Học máy (Machine Learning). Nhóm sử dụng bộ dữ liệu Titanic Passenger Dataset (891 mẫu huấn luyện, 418 mẫu kiểm tra) từ Kaggle.

Quy trình được thực hiện xuyên suốt từ Phân tích dữ liệu khám phá (EDA) – phát hiện các yếu tố quyết định như Giới tính, Hạng vé, Tuổi – đến Kỹ thuật tạo đặc trưng (Feature Engineering) với 7 đặc trưng mới bao gồm Title, FamilySize, IsAlone, Has_Cabin, Deck, Age_Class và Fare_Per_Person. Tiền xử lý dữ liệu được đóng gói trong TitanicUnifiedTransformer tích hợp hoàn toàn vào scikit-learn Pipeline, đảm bảo tránh Data Leakage.

Ba thuật toán được xây dựng và tối ưu qua GridSearchCV 5-Fold Cross-Validation có theo dõi thực nghiệm bằng WandB: Logistic Regression (Elastic Net), Random Forest và Support Vector Machine. Mô hình SVM với Polynomial Kernel (degree=2, C=1) được chọn làm mô hình cuối cùng với Accuracy 81.56%, Precision 81.03%, F1-Score 74.02% và ROC-AUC 82.91%.

Hệ thống được triển khai thành ứng dụng web đầy đủ: backend FastAPI phục vụ endpoint RESTful POST /predict, frontend React với giao diện glassmorphism chủ đề đại dương, cho phép dự đoán theo thời gian thực.

# LỜI CAM ĐOAN:

Chúng em xin cam đoan rằng tiểu luận với đề tài *"Dự đoán khả năng sống sót của hành khách tàu Titanic"* là công trình nghiên cứu do chính nhóm chúng em thực hiện dưới sự hướng dẫn của giảng viên.

Các nội dung, kết quả nghiên cứu và phân tích trong báo cáo là trung thực, được thực hiện dựa trên kiến thức đã học và quá trình tìm hiểu tài liệu. Những tài liệu tham khảo, dữ liệu và công cụ sử dụng trong quá trình thực hiện đều đã được trích dẫn rõ ràng trong phần tài liệu tham khảo.

Chúng em xin hoàn toàn chịu trách nhiệm nếu có bất kỳ sự sao chép hoặc vi phạm bản quyền nào trong nội dung của báo cáo này.

TP. Hồ Chí Minh, ngày 04 tháng 05 năm 2026

Đại diện nhóm thực hiện

Diệp Bảo Doanh

# LỜI CẢM ƠN:

Chúng em xin gửi lời cảm ơn chân thành đến thầy Võ Việt Khoa – giảng viên hướng dẫn môn Trí tuệ nhân tạo – đã tận tình giảng dạy, định hướng và hỗ trợ nhóm trong suốt quá trình thực hiện đề tài. Những góp ý và hướng dẫn quý báu của thầy đã giúp chúng em hoàn thiện bài báo cáo một cách tốt nhất.

Bên cạnh đó, chúng em cũng xin cảm ơn các nguồn tài liệu, cộng đồng học tập và nền tảng như Kaggle đã cung cấp dữ liệu và kiến thức hữu ích phục vụ cho quá trình nghiên cứu.

Mặc dù đã cố gắng hoàn thiện, nhưng do hạn chế về thời gian và kinh nghiệm, bài tiểu luận khó tránh khỏi những thiếu sót. Chúng em rất mong nhận được sự góp ý từ thầy để có thể cải thiện và hoàn thiện hơn trong tương lai.

Chúng em xin chân thành cảm ơn!

# MỤC LỤC

TÓM TẮT: ....2
LỜI CAM ĐOAN: ....3
LỜI CẢM ƠN: ....3
DANH MỤC CÁC BẢNG ....8
CHƯƠNG 1 – GIỚI THIỆU ....9
1.1. Đặt vấn đề ....9
1.2. Lý do chọn đề tài ....9
1.3. Mục tiêu ....9
1.4. Phạm vi đề tài ....9
1.5. Cấu trúc báo cáo ....10
CHƯƠNG 2 – CƠ SỞ LÝ THUYẾT ....11
2.1. Phân tích dữ liệu khám phá (EDA) ....11
2.2. Các thuật toán học máy ....11
2.2.1. Logistic Regression với Elastic Net Regularization ....11
2.2.2. Random Forest ....11
2.2.3. Support Vector Machine – Polynomial Kernel ....11
2.3. Các chỉ số đánh giá mô hình ....11
2.4. scikit-learn Pipeline và Custom Transformer ....12
2.5. GridSearchCV và Cross-Validation ....12
2.6. Công nghệ xây dựng hệ thống ....12
2.6.1. FastAPI – Backend ....12
2.6.2. React + Vite – Frontend ....13
2.6.3. WandB – Theo dõi thực nghiệm ....13
CHƯƠNG 3 – PHÂN TÍCH & THIẾT KẾ ....14
3.1. Mô tả bộ dữ liệu ....14
3.2. Phân tích và xử lý dữ liệu thiếu (Missing Values) ....14
3.3. Kỹ thuật tạo đặc trưng (Feature Engineering) ....15
3.4. Thiết kế Pipeline và Kiến trúc hệ thống ....16
3.4.1. TitanicUnifiedTransformer ....16
3.4.2. Full Pipeline ....16
3.4.3. Kiến trúc ứng dụng web ....16
3.5 Tổng quan bộ dữ liệu và phân bố nhãn ....16
3.6 Phân tích đơn biến (Univariate Analysis) ....17
3.6.1 Biến phân loại (Categorical Features) ....17

3.6.2 Biến liên tục (Numerical Features) ....18
3.7 Phân tích hai biến (Bivariate Analysis) ....20
3.7.1 Biến phân loại ( Categorical ): ....20
3.7.2. Biến liên tục ( Numerical ): ....23
3.8 Phân tích đa biến (Multivariate Analysis): ....26
3.9 Phân tích Feature Engineering: ....27
3.9.1 Family_Size và Family_Cat: ....27
3.9.2 Has_Cabin và Is_Cabin_Missing: ....29
3.9.3 Deck: ....30
3.10 Ma trận tương quan (Correlation Matrix): ....31
CHƯƠNG 4 – TRIỂN KHAI & THỬ NGHIỆM: ....33
4.1. Thiết lập thực nghiệm ....33
4.2. Mô hình 1 – Logistic Regression (Elastic Net) ....33
4.2.1. Không gian tìm kiếm tham số ....33
4.2.2. Kết quả so sánh ....33
4.2.3. Phân tích kết quả ....33
4.3. Mô hình 2 – Random Forest ....34
4.3.1. Không gian tìm kiếm tham số ....34
4.3.2. Kết quả so sánh ....34
4.3.3. Phân tích kết quả ....34
4.4. Mô hình 3 – SVM ....34
4.4.1. Không gian tìm kiếm tham số ....34
4.4.2. Kết quả so sánh ....34
4.4.3. Phân tích kết quả – Tại sao SVM Poly Kernel thắng? ....35
4.5. Đánh giá mô hình cuối cùng ....35
4.6. Triển khai ứng dụng web ....36
4.6.1. Tổng quan về giao diện người dùng: ....36
4.6.2 Chi tiết các thành phần đầu vào (Input Fields): ....37
4.6.3 Kết quả thực nghiệm và Minh chứng (Case Study): ....37
4.6.. Đánh giá tính logic của giao diện và mô hình: ....39
CHƯƠNG 5 – KẾT LUẬN & HƯỚNG PHÁT TRIỂN ....40
5.1. Tóm tắt kết quả đạt được ....40
5.2. Hạn chế ....40
5.3. Hướng phát triển ....40
TÀI LIỆU THAM KHẢO ....42
PHỤ LỤC ....43

A. Hướng dẫn cài đặt và chạy .....43
A.1. Backend .....43
A.2. Frontend.....43
B. Ví dụ Request/Response API.....43
B.1. Request mẫu – POST /predict.....43
B.2. Response mẫu .....43

# DANH MỤC CÁC HÌNH

Hình 3 1: Heatmap trực quan hóa việc mất mát dữ liệu.....15
Hình 3 2: Phân bố nhãn Survived: 549 Không sống sót (61.6%) và 342 Sống sót (38.4%) .....17
Hình 3 3: Phân tích đơn biến các biến phân loại: Pclass, Sex, Embarked, SibSp, Parch, SibSp.....17
Hình 3 4: Phân tích đơn biến các biến liên tục: Age, Fare .....18
Hình 3 5: Phân tích đơn biến của Fare Group .....19
Hình 3 6: Phân tích đơn biến chia theo từng nhóm tuổi dựa theo cột Age .....20
Hình 3 7: Tỉ lệ sống sốt theo các đặc trưng chính .....21
Hình 3 8: Phân tích xu hướng sống sót theo Pclass và Sex.....22
Hình 3.9: Phân bố mật độ và boxplot của Age/Fare theo kết quả sống sót.....23
Hình 3 10: Số lượng sống sót theo Fare Group .....25
Hình 3 11: Số lượng sống sót theo Age Group .....26
Hình 3 12: Phân tích đa biến giữa Pclass, Embarked, Sex.....27
Hình 3 13: Biểu đồ thể hiện sự sống sót theo cột Family Size.....28
Hình 3 14: Biểu đồ thể hiện sự sống sót theo cột Family_Cat.....29
Hình 3 15: Tỉ lệ sống sót theo Deck .....30
Hình 3 16: Lược đồ tương quan .....31

Hình 4 1: So sánh toàn bộ 6 mô hình (Baseline và Tuned) và so sánh 3 mô hình cuối 35
Hình 4 2: Ma trận nhầm lẫn và các chỉ số đánh giá của SVM Final (tập Validation N=179).....36
Hình 4 3: Kết quả sau khi triển khai.....38

# DANH MỤC CÁC BẢNG

Bảng 2 1: Các chỉ số đánh giá mô hình ..... 12

Bảng 3 1: Mô tả chi tiết các đặc trưng trong bộ dữ liệu ..... 14
Bảng 3 2: Tổng hợp tình trạng dữ liệu thiếu và chiến lược xử lý cho từng cột ..... 15
Bảng 3 3: Các đặc trưng mới ..... 16

Bảng 4 1: So sánh Logistic Regression Baseline vs GridSearchCV ..... 33
Bảng 4 2: So sánh Random Forest Baseline vs GridSearchCV ..... 34
Bảng 4 3: So sánh SVM Baseline vs GridSearchCV ..... 35
Bảng 4 4: Tổng hợp chỉ số mô hình SVM cuối cùng (từ metadata v2.0.0) ..... 36

# CHƯƠNG 1 – GIỚI THIỆU

## 1.1. Đặt vấn đề

Vào đêm 14 rạng sáng 15 tháng 4 năm 1912, tàu RMS Titanic – được mệnh danh là con tàu "không thể đắm" – đã chìm xuống Đại Tây Dương sau khi va chạm với một tảng băng trôi. Trong số 2.224 hành khách và thủy thủ đoàn, hơn 1.500 người đã thiệt mạng, trở thành một trong những thảm họa hàng hải kinh hoàng nhất thế kỷ 20.

Điều đáng chú ý là kết quả sống sót không ngẫu nhiên: tỷ lệ sống sót phụ thuộc rõ rệt vào giới tính, độ tuổi, hạng vé và địa vị xã hội – phản ánh bất bình đẳng xã hội thời đại đó. Sự kiện này cung cấp một tập dữ liệu có giá trị để nghiên cứu và xây dựng mô hình dự đoán.

## 1.2. Lý do chọn đề tài

Nhóm lựa chọn đề tài này vì những lý do sau:

- Bộ dữ liệu Titanic là benchmark kinh điển trong ML, có dữ liệu thực tế, ý nghĩa lịch sử rõ ràng và yêu cầu kết hợp nhiều kỹ năng xử lý dữ liệu.
- Bài toán đòi hỏi xử lý dữ liệu thiếu (Missing Values), Feature Engineering sáng tạo và lựa chọn mô hình phân loại – phù hợp với mục tiêu học tập của môn học.
- Cơ hội xây dựng hệ thống AI đầu cuối (end-to-end): từ EDA → Modeling → API → Web UI.
- Có thể theo dõi và so sánh thực nghiệm một cách chuyên nghiệp qua WandB (Weights & Biases).

## 1.3. Mục tiêu

- Thực hiện EDA toàn diện để hiểu phân bố dữ liệu và tương quan các đặc trưng.
- Xây dựng TitanicUnifiedTransformer – custom scikit-learn transformer – cho pipeline hoàn chỉnh.
- So sánh Logistic Regression, Random Forest, SVM; tối ưu siêu tham số bằng GridSearchCV 5-Fold CV.
- Triển khai FastAPI backend và React frontend, tích hợp mô hình cho dự đoán thời gian thực.

## 1.4. Phạm vi đề tài

Đề tài giới hạn trong bài toán phân loại nhị phân (0/1) với bộ dữ liệu Titanic từ Kaggle. Phạm vi kỹ thuật: Python (pandas, scikit-learn, joblib), FastAPI, React/Vite, theo dõi thực nghiệm bằng WandB.

## 1.5. Cấu trúc báo cáo

- Chương 1 – Giới thiệu: Đặt vấn đề, lý do, mục tiêu, phạm vi.
- Chương 2 – Cơ sở lý thuyết: EDA, thuật toán ML, đánh giá mô hình, kiến trúc hệ thống.
- Chương 3 – Phân tích & Thiết kế: Mô tả dữ liệu, xử lý thiếu, Feature Engineering, thiết kế pipeline.
- Chương 4 – Triển khai & Thử nghiệm
- Chương 5 – Kết luận & Hướng phát triển.

# CHƯƠNG 2 – CƠ SỞ LÝ THUYẾT

## 2.1. Phân tích dữ liệu khám phá (EDA)

Exploratory Data Analysis (EDA) là bước đầu tiên và thiết yếu trong mọi dự án khoa học dữ liệu. EDA giúp: (1) hiểu phân bố của từng đặc trưng, (2) phát hiện giá trị ngoại lai (outliers) và dữ liệu thiếu, (3) tìm hiểu mối tương quan giữa các đặc trưng và biến mục tiêu, (4) đặt nền tảng cho Feature Engineering.

EDA bao gồm ba cấp độ phân tích: Phân tích đơn biến (Univariate) xem xét từng đặc trưng riêng lẻ; Phân tích hai biến (Bivariate) khảo sát quan hệ cặp đôi giữa đặc trưng và nhãn; Phân tích đa biến (Multivariate) nghiên cứu tương tác của nhiều biến đồng thời.

## 2.2. Các thuật toán học máy

### 2.2.1. Logistic Regression với Elastic Net Regularization

Logistic Regression sử dụng hàm sigmoid $\sigma(z) = 1/(1+e^{(-z)})$ để ước tính xác suất thuộc lớp dương. Elastic Net kết hợp penalty L1 (Lasso) và L2 (Ridge): $\lambda[\alpha||w||_1 + (1-\alpha)/2\ ||w||_2^2]$, kiểm soát bởi tham số l1_ratio. Nhóm sử dụng solver SAGA – phù hợp với Elastic Net và dữ liệu có kích thước trung bình. Kết quả: C=0.1, l1_ratio=0.5 là tham số tối ưu.

### 2.2.2. Random Forest

Random Forest xây dựng T cây quyết định độc lập trên các tập dữ liệu bootstrap, mỗi cây chỉ xem xét một tập con đặc trưng ngẫu nhiên tại mỗi nút phân chia (feature bagging). Kết quả cuối cùng là biểu quyết đa số. Ưu điểm: kháng overfitting tốt, cung cấp Feature Importance tự nhiên, xử lý tốt dữ liệu phi tuyến và nhiễu. Tham số tối ưu: n_estimators=300, max_depth=20, min_samples_split=10, criterion=gini.

### 2.2.3. Support Vector Machine – Polynomial Kernel

SVM tìm siêu phẳng tối ưu tối đa hóa margin giữa hai lớp. Với dữ liệu phi tuyến, Kernel Trick ánh xạ dữ liệu sang không gian đặc trưng bậc cao hơn mà không cần tính toán tường minh. Polynomial Kernel: $K(x,y) = (\gamma \cdot x^T \cdot y + r)^d$. Với d=2 (bậc 2), mô hình nắm bắt được các tương tác bậc hai giữa đặc trưng – ví dụ: tác động kết hợp của Giới tính và Hạng vé. Tham số cuối: C=1, degree=2, gamma=scale, kernel=poly.

## 2.3. Các chỉ số đánh giá mô hình

Với bài toán phân loại nhị phân có mất cân bằng nhẹ (61.6% vs 38.4%), nhóm sử dụng đồng thời các chỉ số:

| Chỉ số | Công thức | Ý nghĩa thực tế |
|---|---|---|
| Accuracy | (TP+TN)/(TP+TN+FP+FN) | Tỷ lệ dự đoán đúng tổng thể |
| Precision | TP/(TP+FP) | Trong số dự đoán Sống sót, bao nhiêu đúng |
| Recall | TP/(TP+FN) | Trong số Sống sót thực tế, mô hình tìm được bao nhiêu |
| F1-Score | 2·(P·R)/(P+R) | Cân bằng Precision và Recall – tiêu chí tối ưu hóa chính |
| ROC-AUC | Area under ROC curve | Khả năng phân biệt 2 lớp bất kể ngưỡng phân loại |

Bảng 2 1: Các chỉ số đánh giá mô hình

## 2.4. scikit-learn Pipeline và Custom Transformer

scikit-learn Pipeline là chuỗi xử lý gồm các bước biến đổi (transform) liên tiếp kết thúc bằng một estimator. Lợi ích quan trọng nhất: Pipeline đảm bảo tránh Data Leakage – quá trình fit chỉ được thực hiện trên dữ liệu huấn luyện và áp dụng nhất quán lên dữ liệu kiểm tra. Custom Transformer kế thừa BaseEstimator + TransformerMixin, triển khai fit() và transform() để tích hợp liền mạch vào Pipeline.

## 2.5. GridSearchCV và Cross-Validation

GridSearchCV thực hiện duyệt exhaustive trên không gian tham số, đánh giá mỗi tổ hợp bằng k-Fold Cross-Validation. Nhóm sử dụng 5-Fold Stratified CV với refit=F1-Score. Đánh giá bằng CV trung bình (cv_mean) đáng tin cậy hơn single validation vì nó phản ánh khả năng tổng quát hóa thực sự, không phụ thuộc vào may mắn của một lần chia dữ liệu.

## 2.6. Công nghệ xây dựng hệ thống

### 2.6.1. FastAPI – Backend

FastAPI là framework Python hiện đại dựa trên ASGI, hỗ trợ async, tự động sinh Swagger UI/OpenAPI và xác thực dữ liệu qua Pydantic BaseModel. Endpoint POST /predict nhận PassengerInput (11 trường), trả về {"status","prediction","probability_survived"}. Sử dụng sys.modules trick để load joblib model với custom transformer.

### 2.6.2. React + Vite – Frontend

React + Vite cho phép Hot Module Replacement (HMR) tốc độ cao trong phát triển. Giao diện sử dụng CSS thuần (không framework) với hiệu ứng glassmorphism (backdrop-filter: blur), gradient đại dương và 4 section: Hero, About, Prediction Form, How It Works. Form submit gọi fetch() đến API backend, hiển thị kết quả với animation màu sắc.

### 2.6.3. WandB – Theo dõi thực nghiệm

Weights & Biases (WandB) được sử dụng để log toàn bộ hyperparameter, metrics qua từng iteration của GridSearchCV cho 3 mô hình (LR, RF, SVM) trong project "titanic-final-v3". Điều này cho phép so sánh trực quan và tái tạo thực nghiệm một cách minh bạch.

# CHƯƠNG 3 – PHÂN TÍCH & THIẾT KẾ

## 3.1. Mô tả bộ dữ liệu

Bộ dữ liệu Titanic Passenger Dataset từ Kaggle bao gồm hai tập:

- Tập huấn luyện (titanic_train.csv): 891 hành khách, 12 đặc trưng (bao gồm nhãn Survived).
- Tập kiểm tra (titanic_test.csv): 418 hành khách, 11 đặc trưng (không có nhãn Survived).

| Cột | Kiểu | Loại | Mô tả & Ghi chú |
|---|---|---|---|
| PassengerId | int | ID | Mã định danh – không dùng để dự đoán |
| Survived | int | Nhãn | 0 = Không sống sót, 1 = Sống sót (chỉ có trong train) |
| Pclass | int | Categorical | Hạng vé: 1=Nhất, 2=Nhì, 3=Ba – Proxy cho địa vị kinh tế |
| Name | string | Text | Họ tên đầy đủ – dùng để trích xuất Title (danh xưng) |
| Sex | string | Categorical | Giới tính: male / female – Đặc trưng quan trọng nhất |
| Age | float | Numerical | Tuổi – 177 giá trị thiếu (19.9%), điền theo median[Pclass,Sex] |
| SibSp | int | Numerical | Số anh chị em ruột / vợ chồng trên tàu |
| Parch | int | Numerical | Số bố mẹ / con cái trên tàu |
| Ticket | string | Text | Mã số vé – không sử dụng trong mô hình hiện tại |
| Fare | float | Numerical | Giá vé (USD) – liên quan đến Pclass |
| Cabin | string | Text | Số phòng – 687 giá trị thiếu (77.1%), tạo Has_Cabin và Deck |
| Embarked | string | Categorical | Cảng lên tàu: S/C/Q – 2 giá trị thiếu, điền mode="S" |

Bảng 3 1: Mô tả chi tiết các đặc trưng trong bộ dữ liệu

## 3.2. Phân tích và xử lý dữ liệu thiếu (Missing Values)

| Cột | Thiếu | Tỷ lệ | Chiến lược xử lý & Lý do |
|---|---|---|---|
| Age | 177 | 19.9% | Điền median theo nhóm [Pclass, Sex] – phản ánh độ tuổi thực tế của từng tầng xã hội và giới tính. Median ưu tiên hơn Mean vì phân bố Age lệch phải |
| Cabin | 687 | 77.1% | Không điền – tạo Has_Cabin (0/1) và Deck (ký tự đầu). Thiếu Cabin chủ yếu là hành khách Hạng 3 |

| | | | |
|---|---|---|---|
| | | | (98.7% thiếu) – bản thân sự thiếu mặt là tín hiệu quan trọng |
| Embarked | 2 | 0.2% | Điền mode = "S" (Southampton) vì chiếm 72.4% tổng số hành khách – xác suất đúng cao nhất |

Bảng 3 2: Tổng hợp tình trạng dữ liệu thiếu và chiến lược xử lý cho từng cột

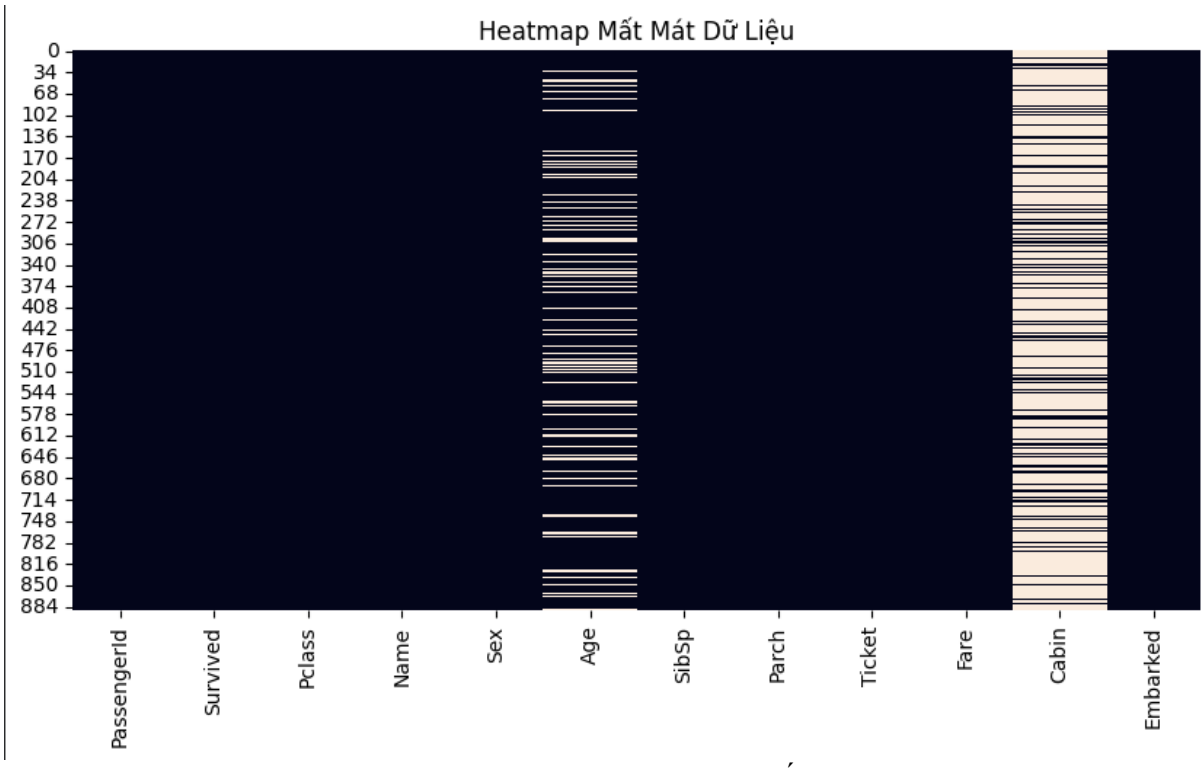


Hình 3 1: Heatmap trực quan hóa việc mất mát dữ liệu

## 3.3. Kỹ thuật tạo đặc trưng (Feature Engineering)

Nhóm tạo thêm 7 đặc trưng mới, được triển khai trong TitanicUnifiedTransformer.transform(). Các đặc trưng này khai thác thêm thông tin tiềm ẩn mà các cột gốc chưa thể hiện trực tiếp:

| Đặc trưng mới | Cách tạo | Lý do và Ý nghĩa |
|---|---|---|
| FamilySize | SibSp + Parch + 1 | Quy mô gia đình thực tế trên tàu. Gia đình nhỏ (2-4) có tỷ lệ sống tốt nhất nhờ hỗ trợ lẫn nhau |
| IsAlone | 1 nếu FamilySize == 1 | Đi một mình (Solo) – tỷ lệ sống chỉ 30.4% so với đi cùng gia đình nhỏ ~55% |
| Has_Cabin | 1 nếu Cabin không rỗng | Proxy cho địa vị xã hội và vị trí phòng. Has_Cabin=1 sống sót 66.7% vs Has_Cabin=0 chỉ 29.9% |
| Deck | Ký tự đầu Cabin, "U"=Unknown | Tầng boong tàu – xác định khoảng cách đến thuyền cứu sinh. Deck B/D/E sống sót 70-80%; Deck U (Hạng 3) chỉ 30% |

| | | |
|---|---|---|
| Title | Regex từ Name | Danh xưng (Mr/Mrs/Miss/Master/Rare) – tổng hợp giới tính, tuổi, địa vị. Master (trẻ em nam) sống 57.5%; Miss/Mrs > 70%; Mr chỉ 15.7% |
| Age_Class | Age × Pclass | Đặc trưng tương tác bậc hai giữa tuổi và hạng vé – tương quan -0.37 với Survived |
| Fare_Per_Person | Fare / FamilySize | Giá vé điều chỉnh theo quy mô gia đình – phản ánh chi phí thực tế mỗi người |

Bảng 3 3: Các đặc trưng mới

## 3.4. Thiết kế Pipeline và Kiến trúc hệ thống

### 3.4.1. TitanicUnifiedTransformer

TitanicUnifiedTransformer kế thừa BaseEstimator và TransformerMixin của scikit-learn, triển khai fit() và transform(). Phương thức fit() học median Age theo nhóm [Pclass, Sex] và mode của Embarked từ tập train. Phương thức transform() áp dụng các biến đổi nhất quán trên bất kỳ tập dữ liệu nào, bao gồm: xử lý giá trị thiếu, tạo 7 đặc trưng mới và trả về 14 đặc trưng cố định.

### 3.4.2. Full Pipeline

Pipeline đầy đủ gồm 2 bước: (1) TitanicUnifiedTransformer → (2) ColumnTransformer [StandardScaler cho 8 đặc trưng số, OneHotEncoder cho 5 đặc trưng phân loại] → (3) SVM Classifier. Toàn bộ được lưu bằng joblib.dump() thành titanic_svm_final.joblib (~610KB), đảm bảo tái tạo hoàn toàn trên server.

### 3.4.3. Kiến trúc ứng dụng web

Hệ thống theo kiến trúc Client-Server. Frontend React gửi POST request đến FastAPI backend với JSON payload. FastAPI load pipeline từ joblib, chạy predict() và predict_proba(), trả về JSON {"prediction": 0/1, "probability_survived": 0.xxxx}. Frontend hiển thị kết quả với UI conditional rendering theo kết quả dự đoán.

## 3.5 Tổng quan bộ dữ liệu và phân bố nhãn

Bộ dữ liệu huấn luyện gồm 891 hành khách. Kết quả sống sót được phân bố: 549 người (61.6%) không sống sót và 342 người (38.4%) sống sót – cho thấy sự mất cân bằng nhẹ giữa hai lớp. Tỷ lệ sống sót thực tế của thảm họa Titanic theo lịch sử là khoảng 31.6%, cao hơn một chút trong dataset do cách lấy mẫu.

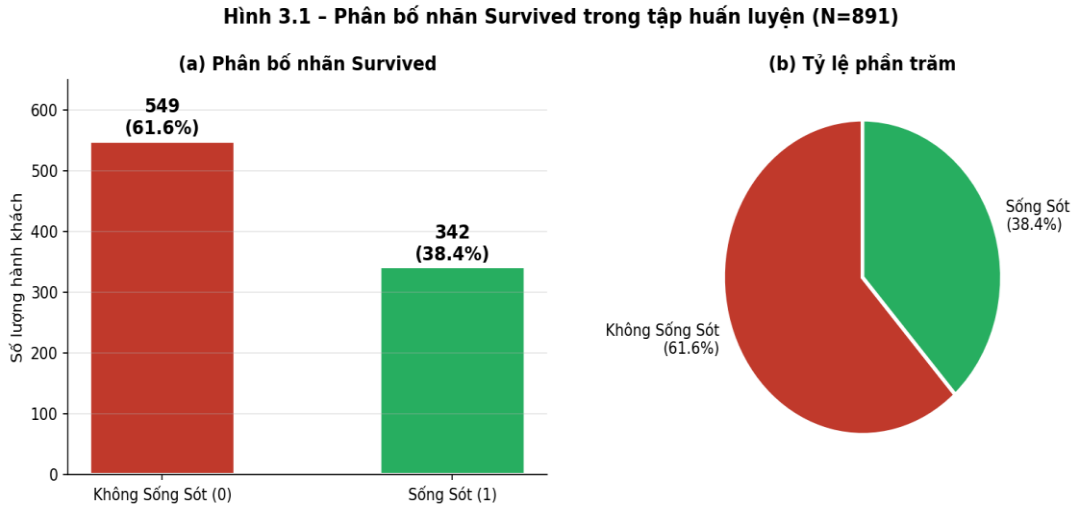


Hình 3 2: Phân bố nhãn Survived: 549 Không sống sót (61.6%) và 342 Sống sót (38.4%)

## 3.6 Phân tích đơn biến (Univariate Analysis)

### 3.6.1 Biến phân loại (Categorical Features)

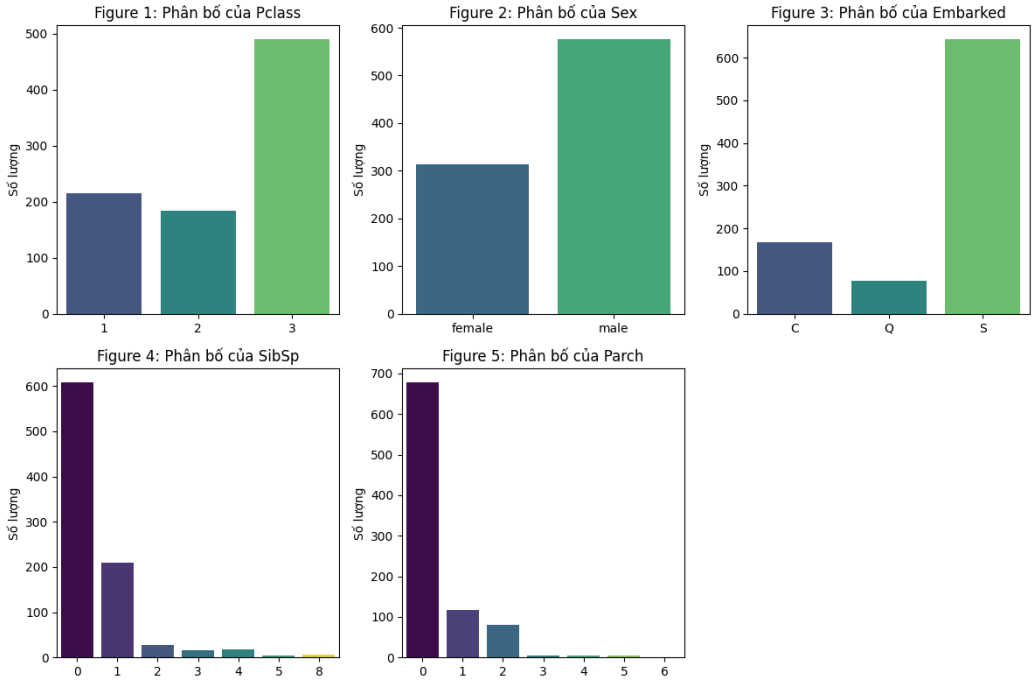


Hình 3 3: Phân tích đơn biến các biến phân loại: Pclass, Sex, Embarked, SibSp, Parch, SibSp

- Biểu đồ cho thấy hành khách hạng 3 (Pclass = 3) chiếm tỷ lệ lớn nhất trong dataset, khoảng hơn một nửa tổng số hành khách, trong khi hạng 1 và hạng 2 có số lượng thấp hơn đáng kể. Điều này phản ánh rằng phần lớn hành khách trên tàu Titanic thuộc tầng lớp trung lưu hoặc lao động với giá vé thấp

- Biểu đồ phân bố giới tính cho thấy số lượng hành khách nam nhiều hơn nữ khá rõ rệt, chiếm khoảng hai phần ba tổng số hành khách trong dataset. Điều này phản ánh đặc điểm xã hội của thời kỳ đó khi nam giới thường chiếm phần lớn trong các chuyến đi dài hoặc di cư

- Biểu đồ cho thấy phần lớn hành khách lên tàu tại cảng Southampton (S), chiếm tỷ lệ áp đảo so với hai cảng còn lại là Cherbourg (C) và Queenstown (Q). Điều này phù hợp với lịch sử khi Titanic khởi hành từ Southampton nên số hành khách tại đây nhiều nhất

- Biểu đồ cho thấy đa số hành khách đi một mình, trong khi các gia đình lớn trên tàu là tương đối ít

- Biểu đồ cho thấy phần lớn hành khách không đi cùng gia đình trực hệ trên tàu

### 3.6.2 Biến liên tục (Numerical Features)

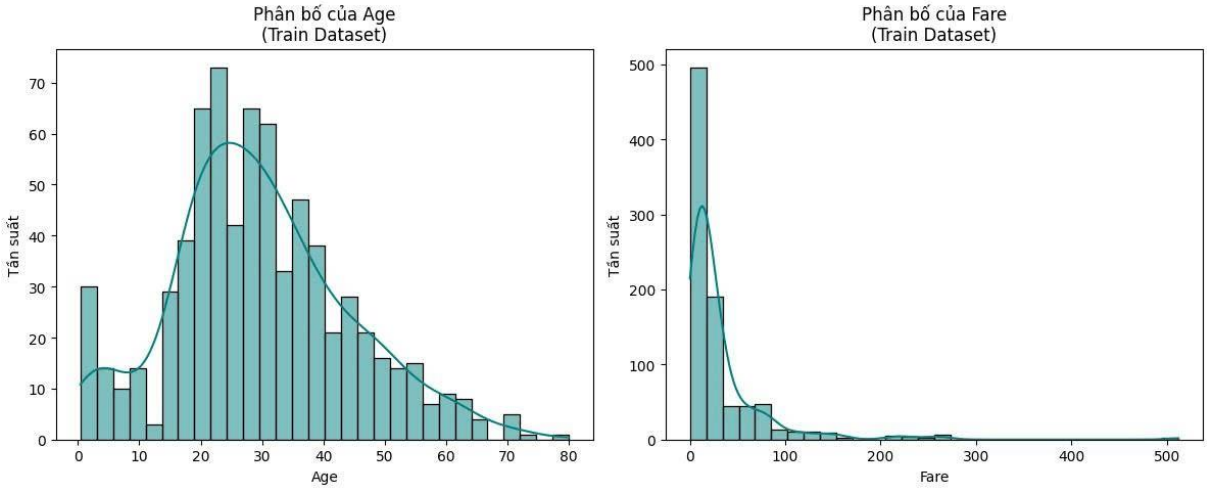


Hình 3 4: Phân tích đơn biến các biến liên tục: Age, Fare

- Về Age: cho thấy độ tuổi hành khách tập trung chủ yếu trong khoảng 20–40 tuổi, với đỉnh phân bố khoảng 30 tuổi, cho thấy phần lớn hành khách là người trưởng thành trẻ. Số lượng trẻ em và người cao tuổi khá ít, và số người giảm dần khi tuổi tăng. Phân bố Age hơi lệch phải, cho thấy vẫn tồn tại một số hành khách lớn tuổi nhưng không nhiều
- Về Fare: có dạng lệch phải, trong đó phần lớn hành khách có giá vé thấp (dưới khoảng 50), trong khi chỉ có một số ít hành khách trả giá vé rất cao, tạo thành positive skewness. Điều này phản ánh sự chênh lệch lớn về điều kiện kinh tế giữa các hành khách trên tàu

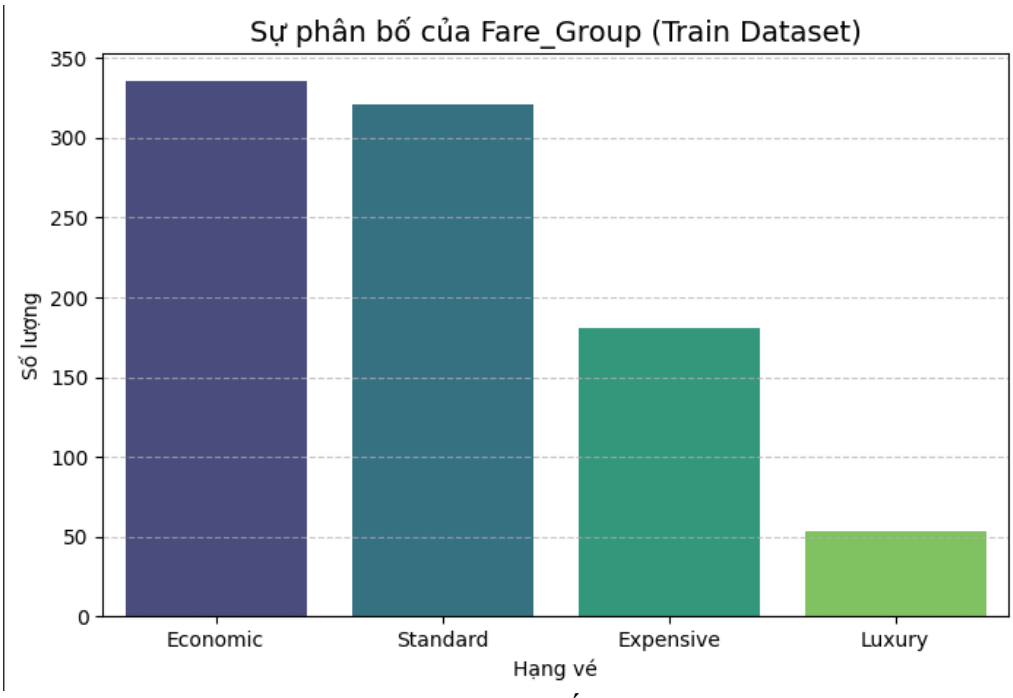


Hình 3 5: Phân tích đơn biến của Fare Group

Hình 3.5 thể hiện số lượng hành khách theo 4 nhóm giá vé đã được phân loại. Chúng ta có thể rút ra các quan sát quan trọng sau:

- Sự chiếm ưu thế của nhóm giá rẻ: Hai nhóm Economic và Standard chiếm tỉ trọng áp đảo trong tổng số hành khách (khoảng hơn 650 người). Điều này cho thấy đa số hành khách trên tàu là tầng lớp lao động hoặc bình dân.
- Cấu trúc hình tháp: Số lượng hành khách giảm dần khi mức giá vé tăng lên. Đây là mô hình kinh tế điển hình: số lượng người có khả năng chi trả cho các mức vé Expensive và đặc biệt là Luxury (chỉ khoảng hơn 50 người) là rất ít.

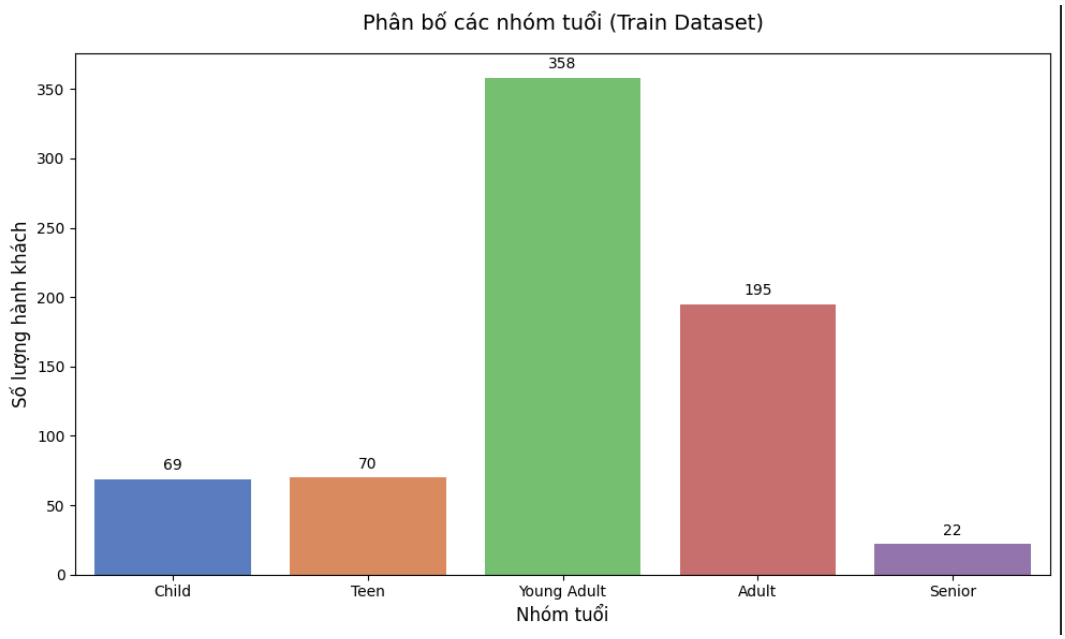


Hình 3 6: Phân tích đơn biến chia theo từng nhóm tuổi dựa theo cột Age

Sau khi phân chia độ tuổi thành các nhóm Child, Teen, Young Adult, Adult và Senior, có thể thấy nhóm Young Adult (18–35 tuổi) chiếm số lượng lớn nhất, vượt trội so với các nhóm còn lại. Nhóm Adult (35–60 tuổi) đứng thứ hai nhưng thấp hơn khá nhiều so với Young Adult. Trong khi đó, các nhóm Child, Teen và đặc biệt là Senior có số lượng khá ít. Điều này cho thấy phần lớn hành khách trên tàu là những người trong độ tuổi trưởng thành trẻ

## 3.7 Phân tích hai biến (Bivariate Analysis)

### 3.7.1 Biến phân loại ( Categorical ):

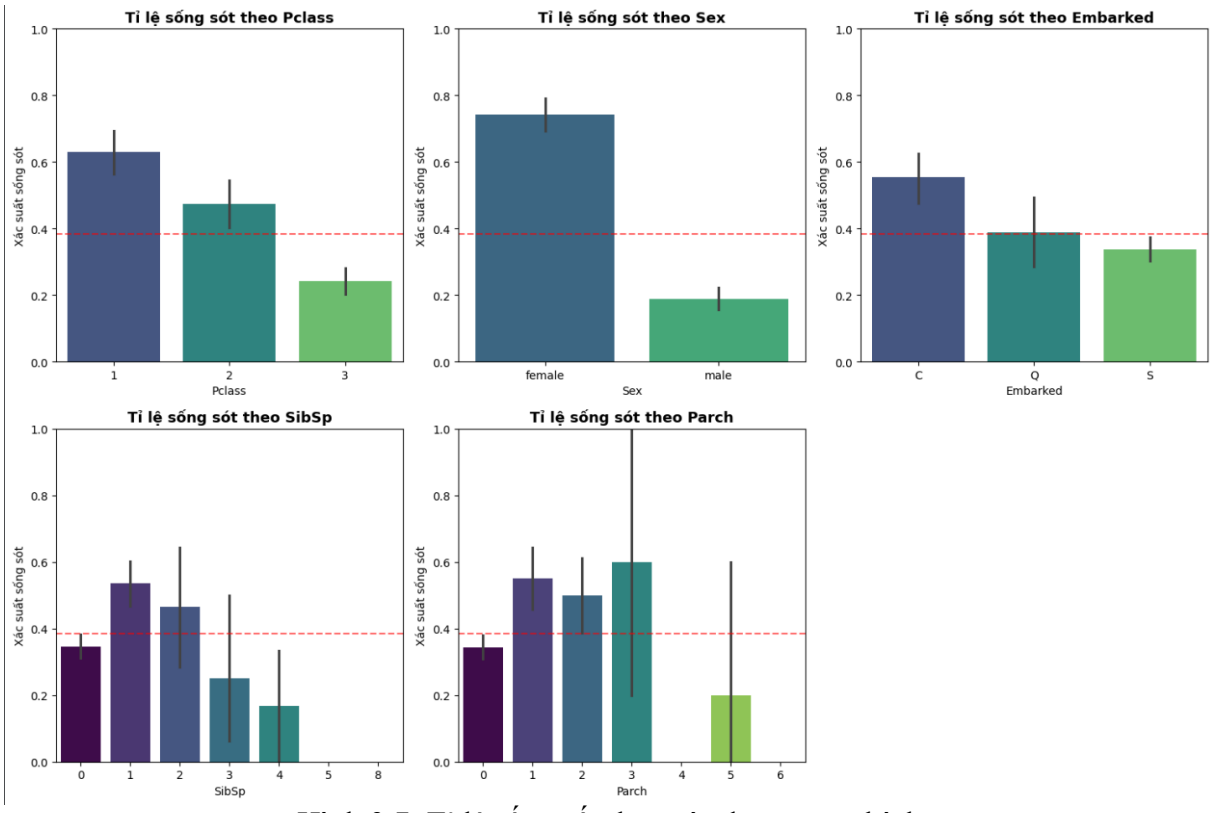


Hình 3 7: Tỉ lệ sống sót theo các đặc trưng chính

**Cái nhìn tổng quan:**

- Tỉ lệ sống sót trung bình của hành khách trong tập dữ liệu là khoảng **38%** (đường đỏ nét đứt). Các biến như Sex, Pclass thể hiện sự phân hóa cực kỳ rõ rệt, trong khi các biến gia đình (SibSp, Parch) cho thấy những xu hướng phức tạp hơn.

**Phân tích chi tiết các biến:**

- Giới tính (Sex): Đây là đặc trưng có khả năng phân loại mạnh nhất. Hành khách Nữ (Female) có tỉ lệ sống sót cao vọt (74%), gấp gần 4 lần so với Nam giới (Male) (~19%). Điều này phù hợp với quy tắc ưu tiên "Phụ nữ và trẻ em" trong thảm họa.
- Hạng vé (Pclass): Có sự phân cấp xã hội rõ rệt trong khả năng sinh tồn. Hành khách Hạng 1 có xác suất sống sót cao nhất (>60%), tiếp theo là Hạng 2 và thấp nhất là Hạng 3 (chỉ khoảng 24%).
- Cảng lên tàu (Embarked): Hành khách lên tàu tại cảng C (Cherbourg) có tỉ lệ sống sót cao nhất (~55%), vượt xa mức trung bình. Cảng S có tỉ lệ thấp nhất.
- Deck 'U' có tỉ lệ sống sót thấp nhất (~30%), nằm dưới mức trung bình (đường đỏ).

- Ý nghĩa: Khoảng tin cậy của cột 'U' rất ngắn, cho thấy kích thước mẫu cực lớn. Điều này khẳng định dữ liệu Cabin bị thiếu chủ yếu tập trung ở hành khách Hạng 3. Việc không có số phòng là một chỉ báo mạnh cho thấy hành khách ở vị trí khó tiếp cận thuyền cứu hộ.
- Nhận xét: Các tầng B, D, E và C đều có tỉ lệ sống sót rất cao (từ 60% đến gần 80%).
- Giải thích: Đây là những tầng nằm ở phía trên của con tàu, chủ yếu dành cho hành khách Hạng 1. Vị trí địa lý gần boong tàu giúp họ thoát hiểm nhanh hơn khi thảm họa xảy ra.

**Lưu ý:** Cần kiểm tra xem có phải hành khách giàu (Pclass 1) tập trung nhiều ở cảng C hay không.

- Mối quan hệ gia đình (SibSp & Parch): * Hành khách đi theo nhóm nhỏ (1-2 người thân đối với SibSp hoặc 1-3 người đối với Parch) có cơ hội sống sót cao hơn so với người đi một mình hoặc đi theo gia đình quá đông.
- Các nhóm có gia đình cực đông (SibSp > 4 hoặc Parch > 4) có tỉ lệ sống sót rất thấp hoặc bằng 0.
- Độ tin cậy: Các vạch đen (sai số) ở nhóm Parch = 3 hoặc Parch = 5 rất dài, cho thấy kích thước mẫu ở các nhóm này rất nhỏ, kết quả về tỉ lệ không mang tính đại diện cao.

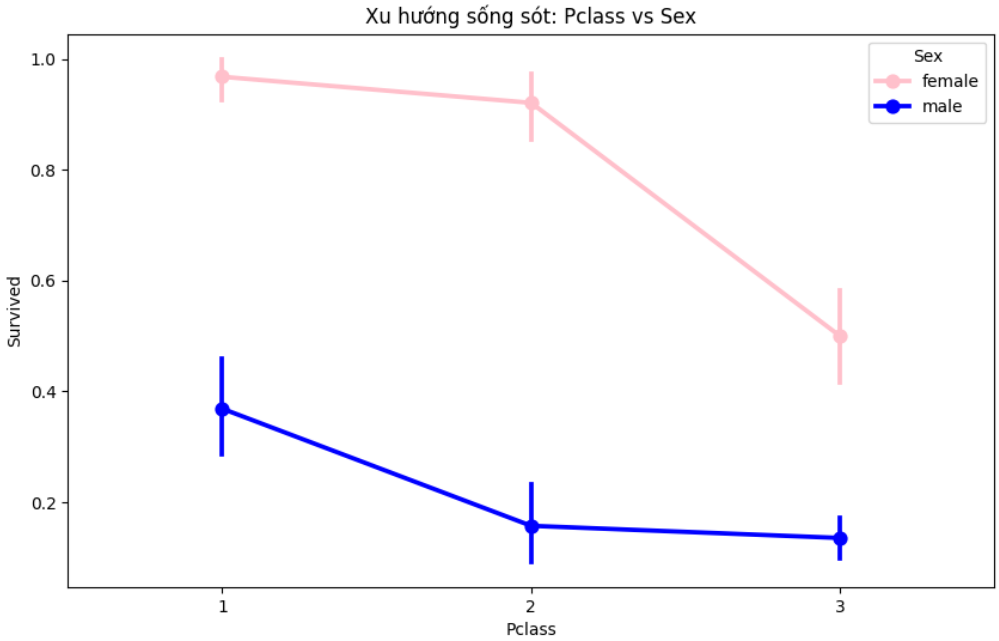


Hình 3 8: Phân tích xu hướng sống sót theo Pclass và Sex

**Xu hướng sống sót (Interaction Plot):**

- Khoảng cách giới tính: Đường biểu diễn của Nữ (Female) luôn nằm cao hơn hẳn Nam (Male), cho thấy giới tính là đặc trưng phân loại mạnh nhất.
- Sự sụt giảm theo Hạng vé: * Đối với Nữ: Tỉ lệ sống sót duy trì ở mức cao tại Hạng 1 và 2, nhưng giảm mạnh khi xuống Hạng 3.
- Đối với Nam: Cơ hội sống sót giảm đều và rõ rệt nhất ngay khi rời khỏi Hạng 1. Hạng 2 và Hạng 3 đối với nam giới đều là những nhóm có rủi ro cực cao.
- Kết luận: Pclass 3 là nhóm chịu ảnh hưởng nặng nề nhất trong thảm họa, đặc biệt là nam giới.

### 3.7.2. Biến liên tục ( Numerical ):

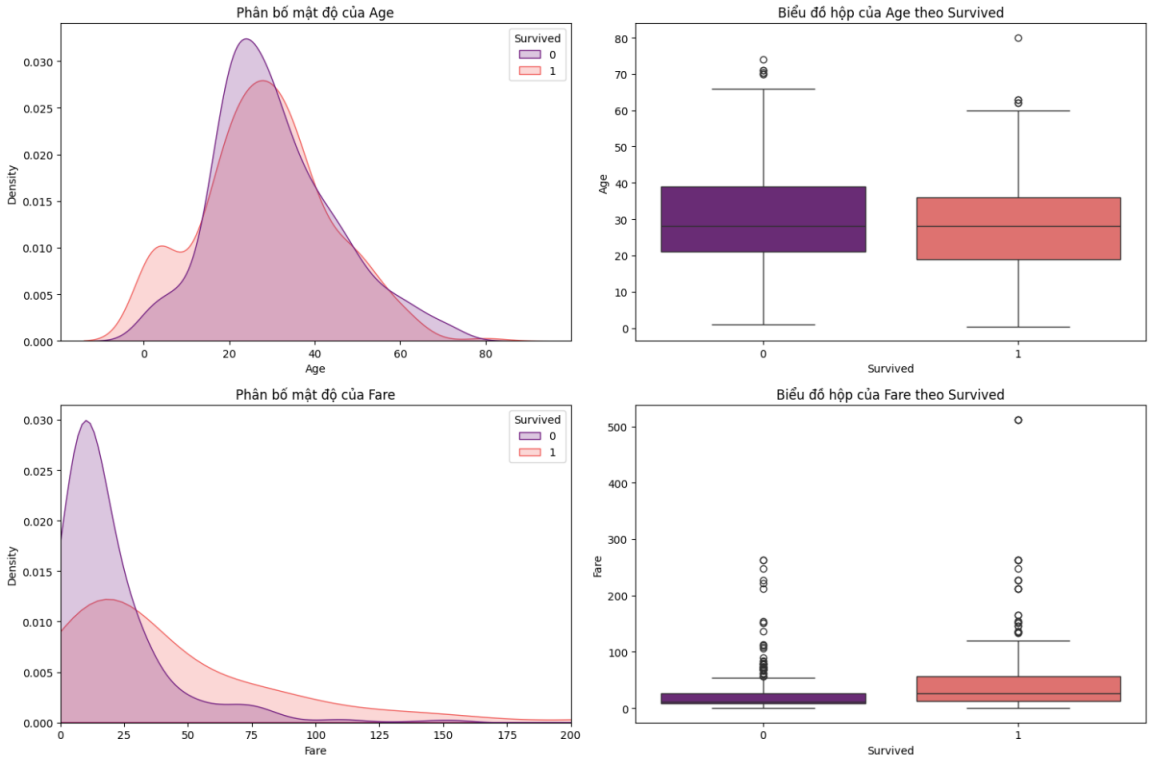


Hình 3.9: Phân bố mật độ và boxplot của Age/Fare theo kết quả sống sót

**Phân tích biến Tuổi (Age):**

- KDE Plot (Trái): Nhìn vào phần đầu vách trái (tầm 0 - 10 tuổi), bạn sẽ thấy đường màu hồng (Survived=1) vọt lên cao hơn hẳn đường màu tím.
- Insight: Điều này khẳng định trẻ em có cơ hội sống sót cao vượt trội. Đây là một "đặc trưng" (feature) cực tốt cho model.

- Vùng 20-40 tuổi: Hai đường chồng lấp lên nhau rất nhiều, nghĩa là ở độ tuổi trưởng thành, yếu tố tuổi tác không còn giúp phân loại "sống/chết" mạnh mẽ bằng các yếu tố khác.
- Box Plot (Phải): Trung vị (vạch ngang ở giữa hộp) của hai nhóm gần như bằng nhau (khoảng 28-30 tuổi).
- Insight: Điều này cho thấy nếu chỉ nhìn vào "độ tuổi trung bình" thì ta sẽ bị lừa là tuổi không quan trọng. Nhưng nhìn vào các dấu chấm (Outliers) ở phía trên (>60 tuổi), ta thấy nhóm tử vong có nhiều người già hơn.

**Phân tích biến Giá vé (Fare):**

- KDE Plot (Trái): Đường màu tím (Not Survived) có một đỉnh cực cao và dốc ở sát mốc 0.
- Insight: Đa số những người thiệt mạng là những người mua vé giá rẻ (tầm dưới 25$). Ngược lại, đường màu hồng (Survived) trải dài và mượt hơn về phía bên phải.
- Box Plot (Phải): Sự chênh lệch của hai hộp.
- Insight: Cái hộp hồng (Survived) nằm cao hơn hẳn hộp tím. Điều này khẳng định: Càng chi nhiều tiền mua vé, xác suất sống càng cao.
- Outliers: Có một dấu chấm ở mốc trên 500$ của nhóm sống sót (đó là những đại gia thực thụ). Những người này gần như chắc chắn được cứu.

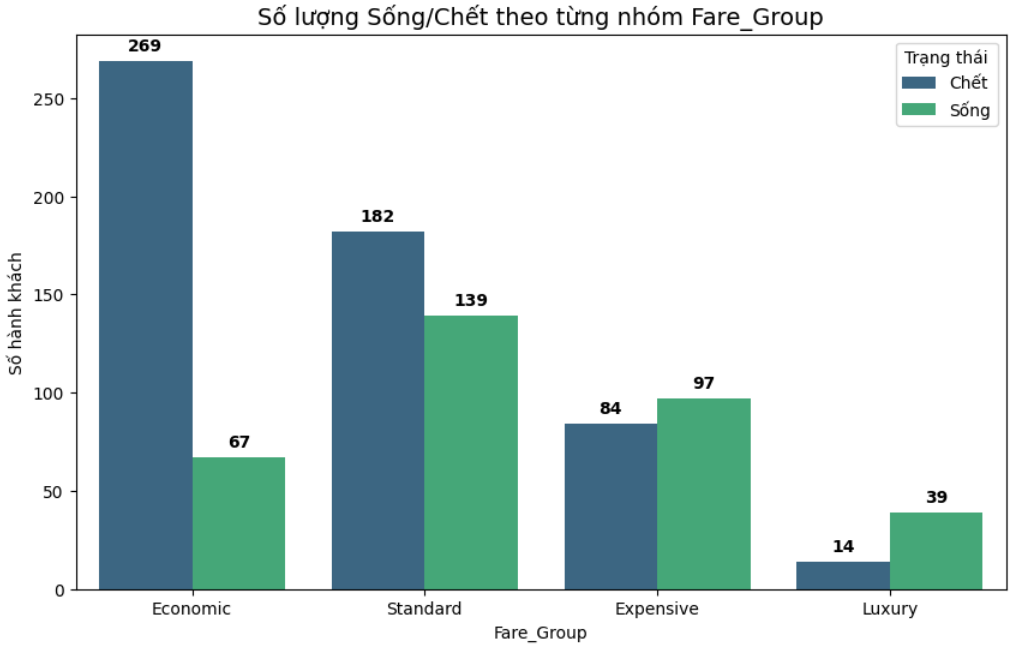


Hình 3 10: Số lượng sống sót theo Fare Group

- Biểu đồ Fare_Group và Survived cho thấy mối quan hệ khá rõ giữa giá vé và khả năng sống sót. Ở nhóm Economic, số người không sống sót vượt trội so với số người sống sót, cho thấy hành khách mua vé rẻ có cơ hội sống thấp hơn. Khi giá vé tăng lên (Standard, Expensive), khoảng cách giữa hai nhóm dần giảm và đến nhóm Expensive thì số người sống sót bắt đầu nhiều hơn
- Ở nhóm Luxury, mặc dù số lượng hành khách ít nhưng tỷ lệ sống sót cao hơn rõ rệt. Điều này cho thấy giá vé càng cao thì khả năng sống sót càng lớn, có thể do liên quan đến hạng khoang và vị trí thuận lợi hơn để tiếp cận thuyền cứu sinh

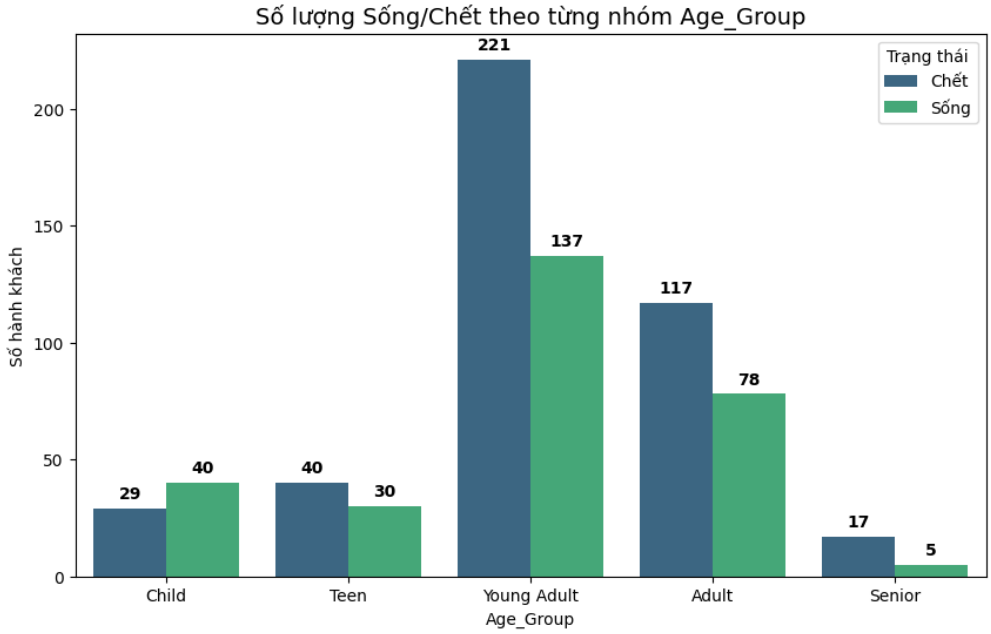


Hình 3 11: Số lượng sống sót theo Age Group

- Nhóm Child có số người sống sót nhiều hơn số không sống, cho thấy trẻ em thường được ưu tiên cứu hộ. Nhóm Teen có tỷ lệ sống và không sống khá gần nhau
- Trong khi đó, nhóm Young Adult và Adult chiếm phần lớn hành khách nhưng số người không sống sót nhiều hơn đáng kể, cho thấy người trưởng thành có tỷ lệ tử vong cao hơn
- Nhóm Senior có số lượng ít và đa phần không sống sót, có thể do hạn chế về thể lực khi sơ tán

## 3.8 Phân tích đa biến (Multivariate Analysis):

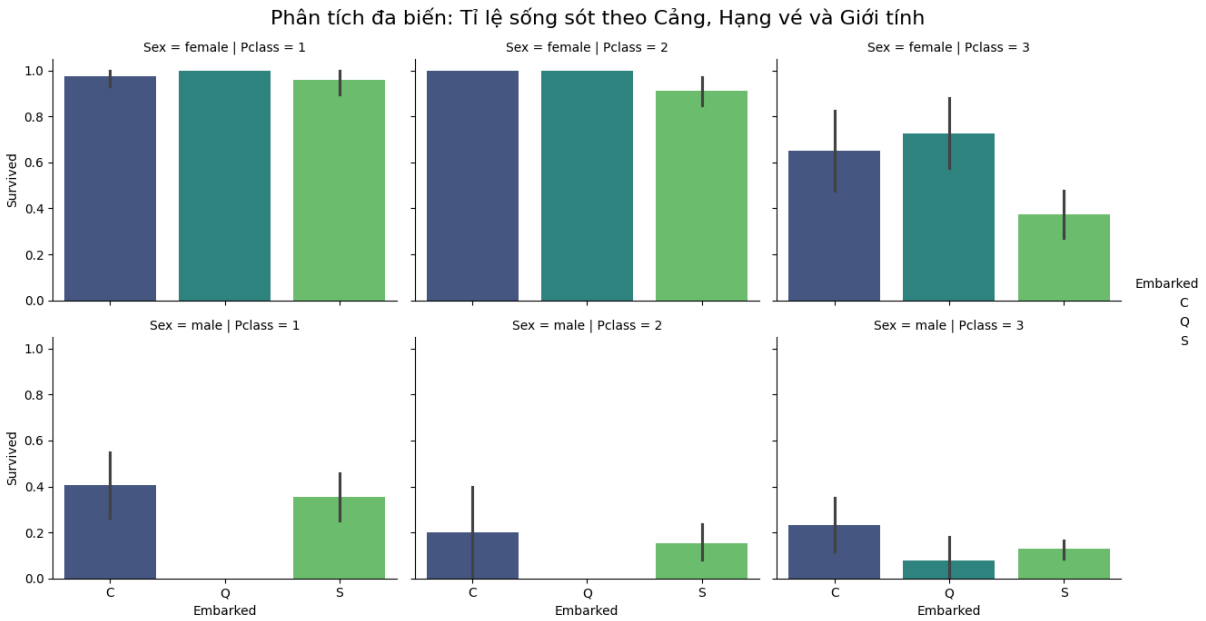


Hình 3 12: Phân tích đa biến giữa Pclass, Embarked, Sex

**Tác động tổng hợp của Giới tính, Hạng vé và Cảng lên tàu:**

- Đặc quyền của Phụ nữ Hạng cao: Phụ nữ thuộc Hạng 1 và Hạng 2 có tỉ lệ sống sót gần như tuyệt đối (~100%) bất kể họ lên tàu ở cảng nào.
- Sự khác biệt ở Hạng 3: Phụ nữ Hạng 3 có tỉ lệ sống sót thấp hơn nhiều và biến động mạnh theo cảng (Cảng C và Q có tỉ lệ sống sót cao hơn cảng S).
- Nam giới và Hạng vé: Ngay cả nam giới ở Hạng 1 (giàu nhất) cũng có tỉ lệ sống sót thấp hơn nhiều so với phụ nữ ở Hạng 3 (nghèo nhất). Điều này khẳng định yếu tố Giới tính (Sex) có trọng số cao hơn Hạng vé (Pclass) trong mô hình dự đoán.

## 3.9 Phân tích Feature Engineering:

### 3.9.1 Family_Size và Family_Cat:

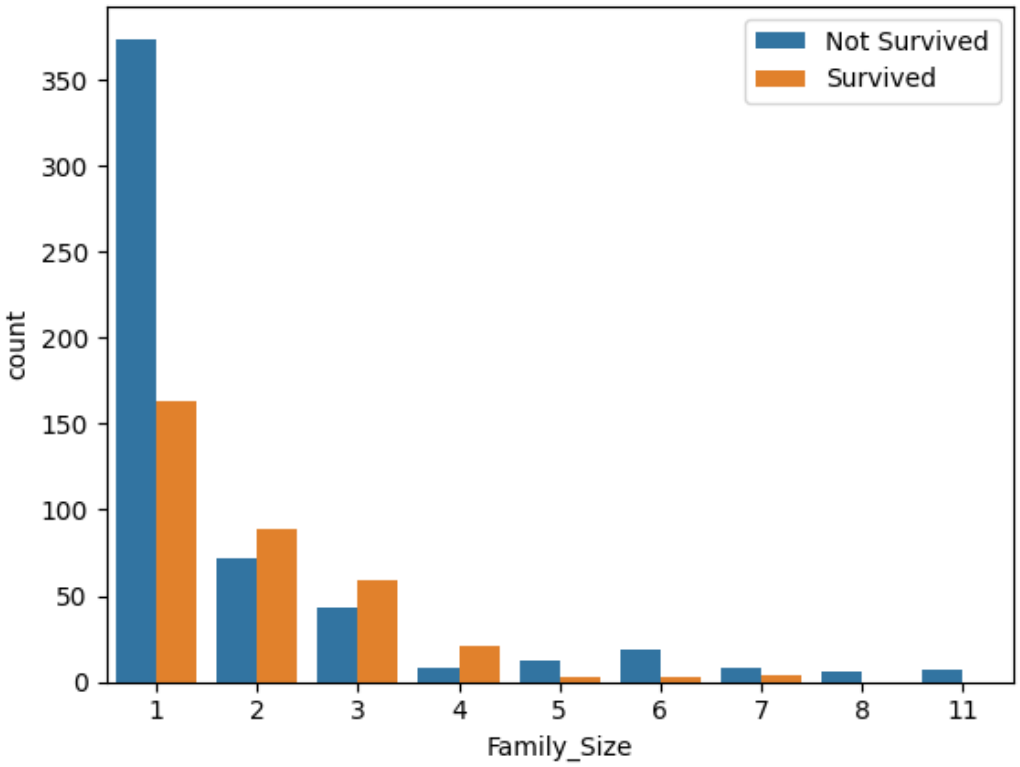


Hình 3 13: Biểu đồ thể hiện sự sống sót theo cột Family Size

- Phần lớn hành khách có Family_Size = 1 (đi một mình), và trong nhóm này số người không sống sót nhiều hơn đáng kể so với số người sống sót
- Khi Family_Size tăng lên khoảng 2–4, số người sống sót bắt đầu cao hơn hoặc gần tương đương với số người không sống sót, cho thấy những hành khách đi cùng gia đình nhỏ có xu hướng có cơ hội sống sót tốt hơn, có thể do hỗ trợ lẫn nhau trong quá trình sơ tán
- Tuy nhiên, khi Family_Size quá lớn (>= 5), số người không sống sót tăng lên rõ rệt và số người sống sót rất ít. Điều này cho thấy gia đình quá đông có thể gặp ó khăn trong việc di chuyển và lên thuyền cứu sinh kịp thời

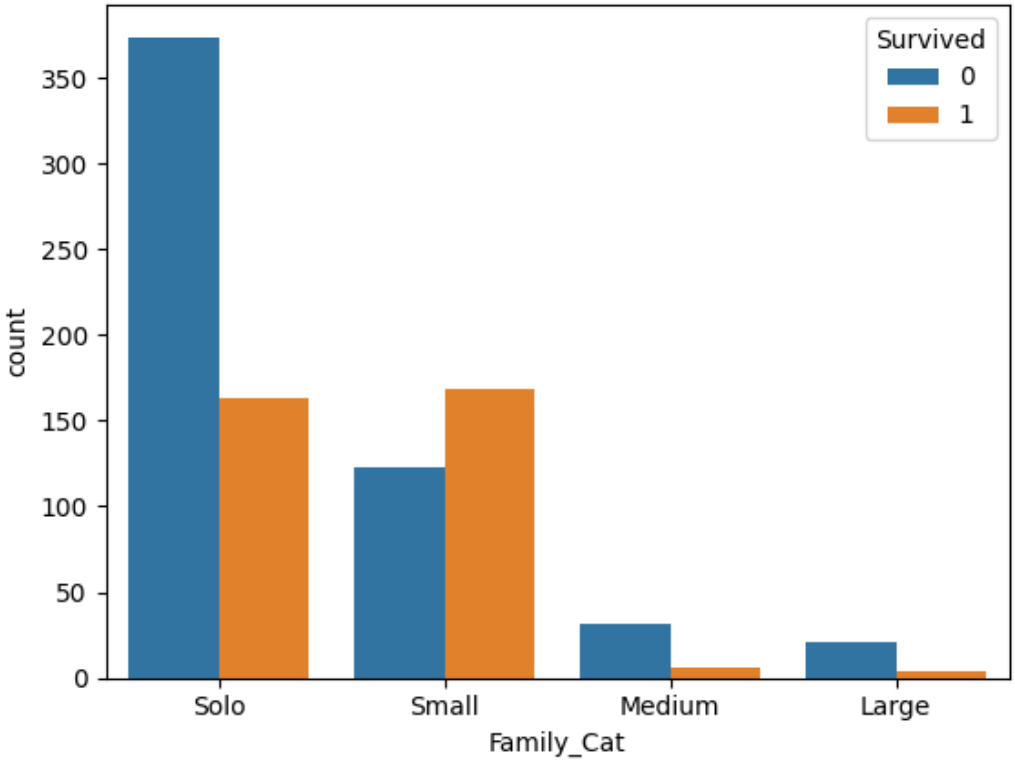


Hình 3 14: Biểu đồ thể hiện sự sống sót theo cột Family_Cat

**Lý do tạo cột Family_Size và Family_Cat:**

- Việc tạo ra Family_Size và phân loại thành Family_Cat giúp mô hình nắm bắt được mối quan hệ xã hội và khả năng hỗ trợ lẫn nhau giữa các hành khách. Trong thảm họa Titanic, những người đi một mình (Solo) thường thiếu sự trợ giúp, trong khi các gia đình quá đông (Large) lại gặp khó khăn trong việc tập hợp đầy đủ thành viên để lên thuyền cứu hộ kịp lúc.
- Nhóm gia đình nhỏ (Small) thường có tỉ lệ sống sót cao nhất nhờ sự linh hoạt và hỗ trợ nhóm hiệu quả. Bằng cách gom nhóm này ta chuyển đổi những con số rời rạc (SibSp, Parch) thành một đặc trưng có ý nghĩa trực tiếp đến khả năng sinh tồn

### 3.9.2 Has_Cabin và Is_Cabin_Missing:

**Lý do tạo cột Has_Cabin và Is_Missing_Cabin:**

- Việc tạo ra biến Has_Cabin để khai thác dấu hiệu của sự giàu có và địa vị. Dữ liệu cho thấy những hành khách có số phòng cụ thể thường thuộc Hạng nhất (Pclass 1), trong khi dữ liệu thiếu (Is_Cabin_Missing) tập trung chủ yếu ở Hạng ba.

- Việc sở hữu một Cabin không chỉ đại diện cho số tiền họ bỏ ra mà còn cho thấy vị trí phòng ở của họ nằm ở các khu vực tách biệt, thường gần với boong tàu và các phương tiện cứu hộ hơn so với những người ở khoang phổ thông

### 3.9.3 Deck:

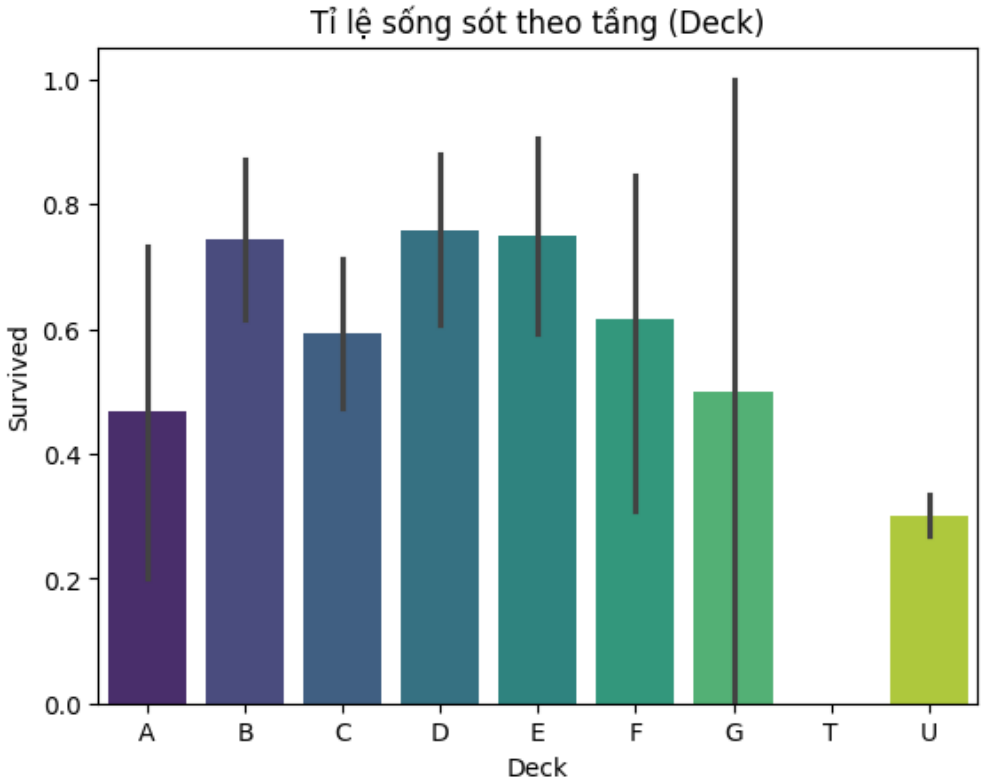


Hình 3 15: Tỉ lệ sống sót theo Deck

**Nhóm U (Unknown):**

- Nhìn vào cột 'U' (Cột đầu tiên bên trái): Tỉ lệ sống sót chỉ lẹt đẹt quanh mức 30%.
- Điểm quan trọng: Cái vạch đen (sai số) trên đầu cột 'U' cực kỳ ngắn.
- Dưới góc độ thống kê: Điều này có nghĩa là mẫu của nhóm 'U' rất lớn (chiếm đa số hành khách).
- Dưới góc độ nghiệp vụ: Nó khẳng định lại giả thuyết của chúng ta: Những người không có số phòng (đại đa số là Hạng 3) có cơ hội sống sót thấp nhất.

**Decks B, D, E:**

- Các tầng B, D, E có tỉ lệ sống sót cao vọt (từ 70% đến 80%).
- Giải thích: Đây là các tầng phía trên, gần boong tàu. Khi có sự cố, họ là những người đầu tiên tiếp cận được thuyền cứu hộ. Việc giữ lại thông tin này giúp Model nhận diện được nhóm "VIP" một cách chính xác.

**Decks G, T, A, F:**

- Deck G: Tỉ lệ sống nhìn là 50% nhưng vạch sai số chạy từ 0 lên tận 1.0! Điều này có nghĩa là nhóm này chỉ có vài ba người (mẫu quá nhỏ), không mang tính đại diện cao.
- Deck T: Tỉ lệ sống bằng 0. Trong thực tế lịch sử, chỉ có duy nhất 1 người ở tầng T, và người đó đã không may mắn thoát nạn.

**Lý do tạo cột Deck**: Việc tách ký tự đầu tiên từ mã Cabin để tạo cột Deck giúp xác định vị trí địa lý theo chiều dọc của hành khách trên tàu. Các tầng boong khác nhau (A, B, C, D...) có khoảng cách tới thuyền cứu hộ và mặt nước hoàn toàn khác nhau

## 3.10 Ma trận tương quan (Correlation Matrix):

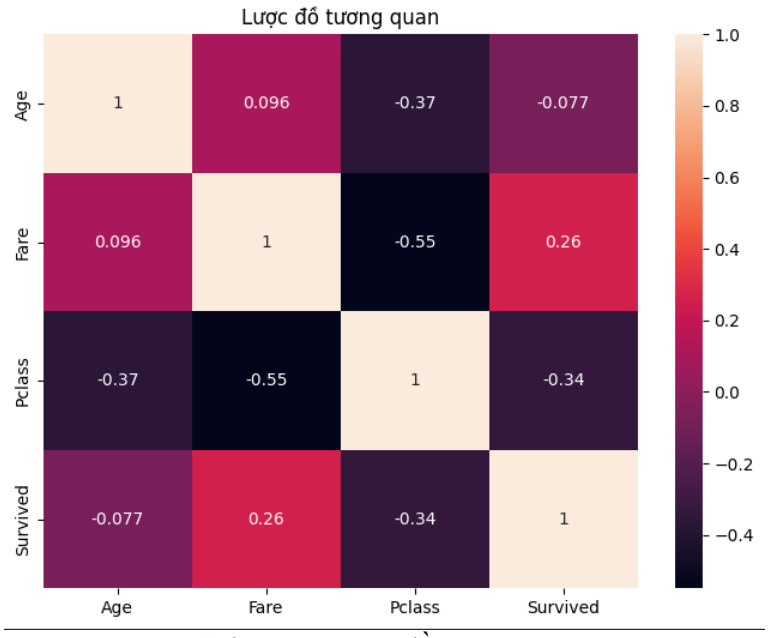


Hình 3 16: Lược đồ tương quan

Lược đồ tương quan cho thấy mối quan hệ giữa các biến Age, Fare, Pclass và Survived:

- Trong đó, biến Pclass có tương quan âm khá rõ với Survived (-0.34), nghĩa là hành khách ở hạng vé thấp hơn (hạng 3) có tỷ lệ sống sót thấp hơn so với hạng cao (hạng 1).
- Biến Fare có tương quan dương với Survived (0.26), cho thấy những người trả giá vé cao hơn thường có khả năng sống sót cao hơn, điều này hợp lý vì giá vé phản ánh điều kiện và vị trí tốt hơn trên tàu.
- Ngược lại, Age có tương quan rất yếu với Survived (-0.077), nên tuổi gần như không ảnh hưởng đáng kể đến khả năng sống sót.

- Ngoài ra, giữa các biến độc lập cũng có những mối liên hệ đáng chú ý. Fare và Pclass có tương quan âm mạnh (-0.55), chứng tỏ hành khách ở hạng cao thường trả giá vé cao hơn. Age và Pclass có tương quan âm mức trung bình (-0.37), cho thấy người lớn tuổi có xu hướng ở hạng cao hơn. Trong khi đó, Age và Fare gần như không có mối liên hệ đáng kể (0.096).
- Từ các phân tích trên, có thể kết luận rằng Pclass và Fare là hai yếu tố quan trọng hơn trong việc dự đoán khả năng sống sót của hành khách, trong khi Age không phải là biến có sức ảnh hưởng lớn. Tuy nhiên, cần lưu ý rằng tương quan không đồng nghĩa với quan hệ nhân quả, và một số biến có thể gián tiếp phản ánh các yếu tố khác như điều kiện kinh tế hoặc vị trí trên tàu.

# CHƯƠNG 4 – TRIỂN KHAI & THỬ NGHIỆM:

## 4.1. Thiết lập thực nghiệm

Dữ liệu 891 mẫu được chia train/validation theo tỷ lệ 80/20 (Stratified Split, random_state=42): 712 mẫu train (452 không sống sót, 260 sống sót) và 179 mẫu validation (97 không sống sót, 82 sống sót). Stratified Split đảm bảo giữ nguyên tỷ lệ lớp trong cả hai tập.

Quy trình tiền xử lý đầy đủ: TitanicUnifiedTransformer → ColumnTransformer (StandardScaler cho 8 số, OneHotEncoder cho 5 phân loại) → mô hình. Pipeline được fit chỉ trên X_train_raw, transform áp dụng nhất quán cho cả train và validation. GridSearchCV dùng 5-Fold CV với refit=F1-Score; mọi thực nghiệm được log lên WandB project "titanic-final-v3".

## 4.2. Mô hình 1 – Logistic Regression (Elastic Net)

### 4.2.1. Không gian tìm kiếm tham số

GridSearchCV duyệt qua: C ∈ {0.01, 0.1, 1.0, 10.0, 100.0} × l1_ratio ∈ {0.0, 0.2, 0.5, 0.7, 1.0} × penalty=elasticnet × solver=saga. Tổng cộng 25 tổ hợp × 5-fold = 125 lần huấn luyện.

### 4.2.2. Kết quả so sánh

Bảng 4.1 – So sánh Logistic Regression Baseline vs GridSearchCV:

| Chỉ số | Baseline (Single Split) | GridSearchCV (5-Fold CV Mean) | Trạng thái |
|---|---|---|---|
| F1-Score | 0.78788 | 0.76325 (Best CV) | Giảm nhẹ – CV trung thực hơn |
| Accuracy | 0.84358 | 0.81608 | Giảm nhẹ |
| ROC-AUC | 0.86785 | 0.86004 | Ổn định |
| Precision | 0.82540 | 0.76153 | Giảm |
| Recall | 0.75362 | 0.75852 | Tăng nhẹ |

Bảng 4 1: So sánh Logistic Regression Baseline vs GridSearchCV

### 4.2.3. Phân tích kết quả

Chỉ số Baseline cao hơn CV không phải mô hình tốt hơn – đó là "Lucky Split". Con số 5-Fold CV 0.763 mới là chỉ số thực tế đáng tin cậy. Mô hình tối ưu chọn C=0.1 (regularization mạnh hơn mặc định), l1_ratio=0.5 (Elastic Net cân bằng L1+L2) – ép

mô hình tổng quát hóa tốt hơn. ROC-AUC ổn định (0.86) cho thấy LR phân biệt 2 lớp tốt mặc dù ranh giới quyết định tuyến tính.

## 4.3. Mô hình 2 – Random Forest

### 4.3.1. Không gian tìm kiếm tham số

GridSearchCV duyệt: n_estimators ∈ {100, 300} × max_depth ∈ {5, 10, 20} × min_samples_split ∈ {2, 10} × criterion ∈ {gini}. Tổng 12 tổ hợp × 5-fold = 60 lần huấn luyện.

### 4.3.2. Kết quả so sánh

| Chỉ số | Baseline (Mặc định) | GridSearchCV (5-Fold CV) | Cải thiện |
|---|---|---|---|
| F1-Score | 0.71756 | 0.76531 | +4.77% ↑ |
| Accuracy | 0.79330 | 0.83016 | +3.686% ↑ |
| ROC-AUC | 0.84269 | 0.87980 | +3.711% ↑ – Cao nhất |
| Precision | 0.75806 | 0.82346 | +6.540% ↑ |
| Recall | 0.68116 | 0.70727 | +2.611% ↑ |

Bảng 4 2: So sánh Random Forest Baseline vs GridSearchCV

### 4.3.3. Phân tích kết quả

Random Forest là mô hình cải thiện nhiều nhất sau tuning – tất cả chỉ số đều tăng. Tham số tối ưu max_depth=20 và min_samples_split=10 ngăn cây phát triển quá sâu (overfitting). ROC-AUC 0.8798 cao nhất trong 3 mô hình – RF phân biệt 2 lớp rất tốt. Tuy nhiên F1-Score (0.765) chỉ ngang ngửa với SVM, trong khi SVM có tính ổn định cao hơn qua các fold CV.

## 4.4. Mô hình 3 – SVM

### 4.4.1. Không gian tìm kiếm tham số

GridSearchCV duyệt hai nhóm: (1) Linear kernel: C ∈ {0.1, 1, 10, 100}. (2) RBF & Poly kernel: C ∈ {0.1, 1, 10, 100} × gamma ∈ {0.1, 0.01, 0.001, scale, auto} × kernel ∈ {rbf, poly} × degree ∈ {2, 3}. Tổng ~84 tổ hợp × 5-fold = 420 lần huấn luyện.

### 4.4.2. Kết quả so sánh

| Chỉ số | Baseline (Mặc định) | GridSearchCV (5-Fold CV) | Trạng thái |
|---|---|---|---|

| | | | |
|---|---|---|---|
| F1-Score | 0.75591 | 0.76779 (Best CV) | Tăng trưởng ↑ – Cao nhất |
| Accuracy | 0.82682 | 0.81745 | Giảm nhẹ |
| ROC-AUC | 0.85059 | 0.85120 | Tăng nhẹ ↑ |
| Precision | 0.82759 | 0.80670 | Giảm nhẹ |
| Recall | 0.69565 | 0.69253 | Ổn định |

Bảng 4 3: So sánh SVM Baseline vs GridSearchCV

### 4.4.3. Phân tích kết quả – Tại sao SVM Poly Kernel thắng?

Tham số tối ưu: C=1, degree=2, gamma=scale, kernel=poly. Kernel Poly bậc 2 nắm bắt được các tương tác phi tuyến bậc hai giữa đặc trưng – ví dụ: tác động kết hợp Sex×Pclass, Age×FamilySize mà Logistic Regression tuyến tính không thể biểu diễn. C=1 tạo "biên" đủ rộng, ưu tiên tổng quát hóa hơn fit chặt dữ liệu train. F1-Score 5-Fold CV 0.7678 là cao nhất – tiêu chí tối ưu hóa chính. StandardScaler trong pipeline đóng vai trò then chốt vì SVM cực nhạy với thang đo đặc trưng.

## 4.5. Đánh giá mô hình cuối cùng

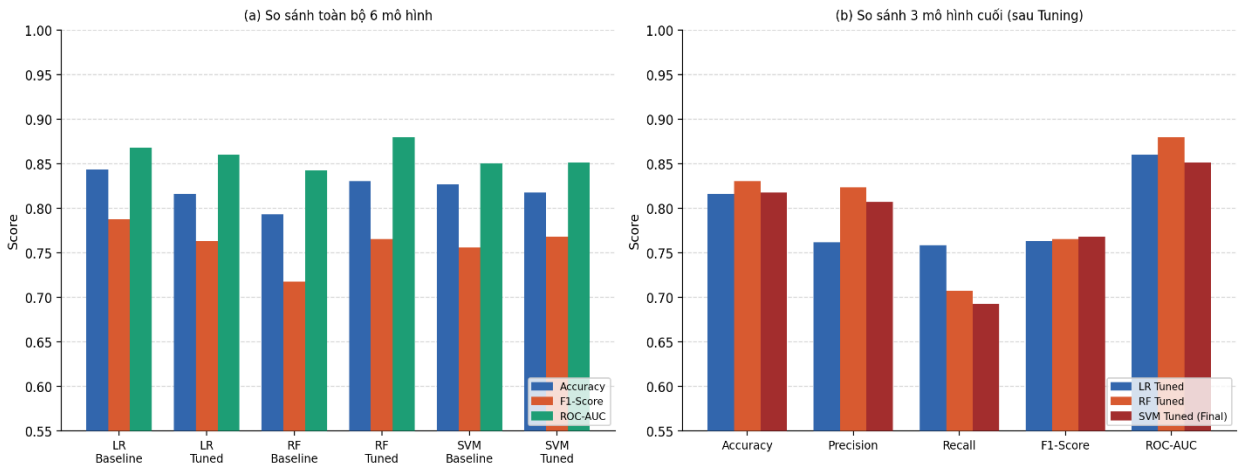


Hình 4 1: So sánh toàn bộ 6 mô hình (Baseline và Tuned) và so sánh 3 mô hình cuối

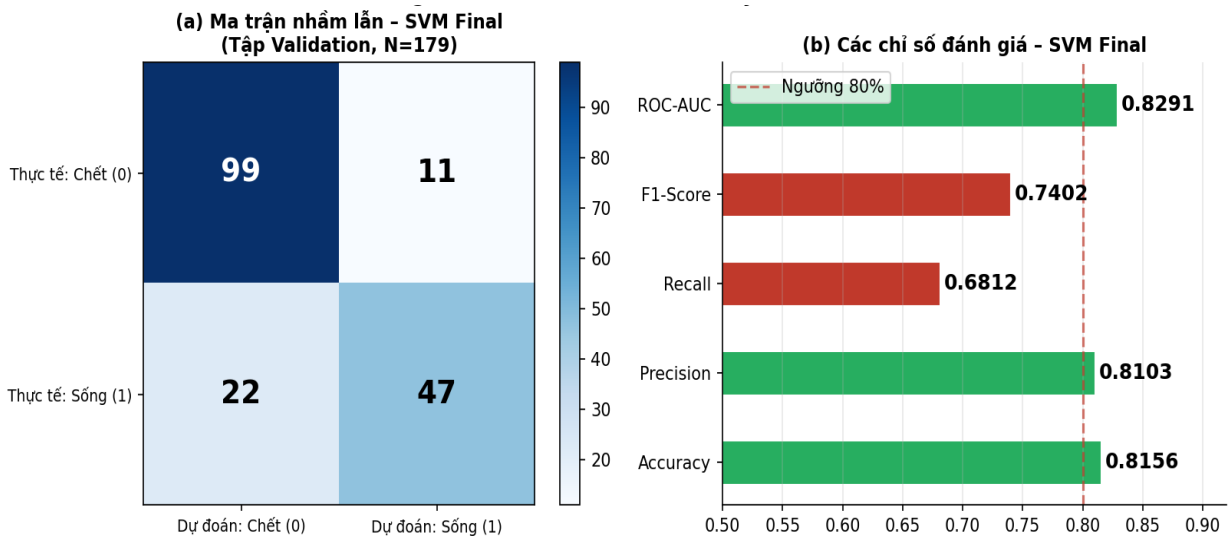


Hình 4 2: Ma trận nhầm lẫn và các chỉ số đánh giá của SVM Final (tập Validation N=179)

Ma trận nhầm lẫn ước tính: TN=99 (đúng – Chết), TP=47 (đúng – Sống), FP=11 (sai – dự đoán Sống nhưng thực tế Chết), FN=22 (sai – dự đoán Chết nhưng thực tế Sống). Tổng Accuracy = (99+47)/179 = 81.6%. Mô hình có xu hướng conservative – ít over-predict Sống (FP nhỏ), giúp Precision cao (81.0%).

| Accuracy | Precision | Recall | F1-Score |
|---|---|---|---|
| 0.8156 (81.56%) | 0.8103 (81.03%) | 0.6812 (68.12%) | 0.7402 (74.02%) |

| ROC-AUC | Kernel / Tham số |
|---|---|
| 0.8291 (82.91%) | Poly, C=1, degree=2, gamma=scale |

Bảng 4 4: Tổng hợp chỉ số mô hình SVM cuối cùng (từ metadata v2.0.0)

## 4.6. Triển khai ứng dụng web

### 4.6.1. Tổng quan về giao diện người dùng:

Giao diện ứng dụng được thiết kế theo phong cách hiện đại, tối giản trên nền tảng Web, tập trung vào trải nghiệm người dùng (User Experience). Ứng dụng cho phép

người dùng nhập các thông số cá nhân của một hành khách giả định để hệ thống thực hiện dự báo khả năng sống sót dựa trên mô hình **Support Vector Machine (SVM)** đã được tối ưu hóa.

### 4.6.2 Chi tiết các thành phần đầu vào (Input Fields):

Hệ thống cung cấp một biểu mẫu (Form) nhập liệu toàn diện, bao gồm các trường thông tin cần thiết để phục vụ cho bộ biến đổi dữ liệu (Pipeline) ở phía Backend:

- **Họ và Tên:** Trường dữ liệu quan trọng nhất để trích xuất **Danh xưng (Title)**. Giao diện có dòng hướng dẫn cụ thể: *"Nên kèm danh xưng: Mr., Mrs., Miss."* để đảm bảo bộ tiền xử lý TitanicUnifiedTransformer hoạt động chính xác.
- **Thông tin sinh trắc và xã hội:** Bao gồm **Tuổi (Age)**, **Giới tính (Gender)** và **Hạng vé (Pclass)** dưới dạng danh sách chọn (Dropdown) để hạn chế sai sót dữ liệu.
- **Thông tin kinh tế: Phí vé (Fare)** giúp mô hình đánh giá vị thế kinh tế của hành khách.
- **Thông tin hành trình: Cảng lên tàu (Embarked)** và **Số phòng (Cabin)**. Trường Cabin giúp hệ thống xác định vị trí tầng boong (Deck) của hành khách.
- **Mối quan hệ gia đình:** Hai trường **SibSp** (Số anh chị em/vợ chồng) và **Parch** (Số con cái/bố mẹ) để tính toán tổng quy mô gia đình (FamilySize).

### 4.6.3 Kết quả thực nghiệm và Minh chứng (Case Study):

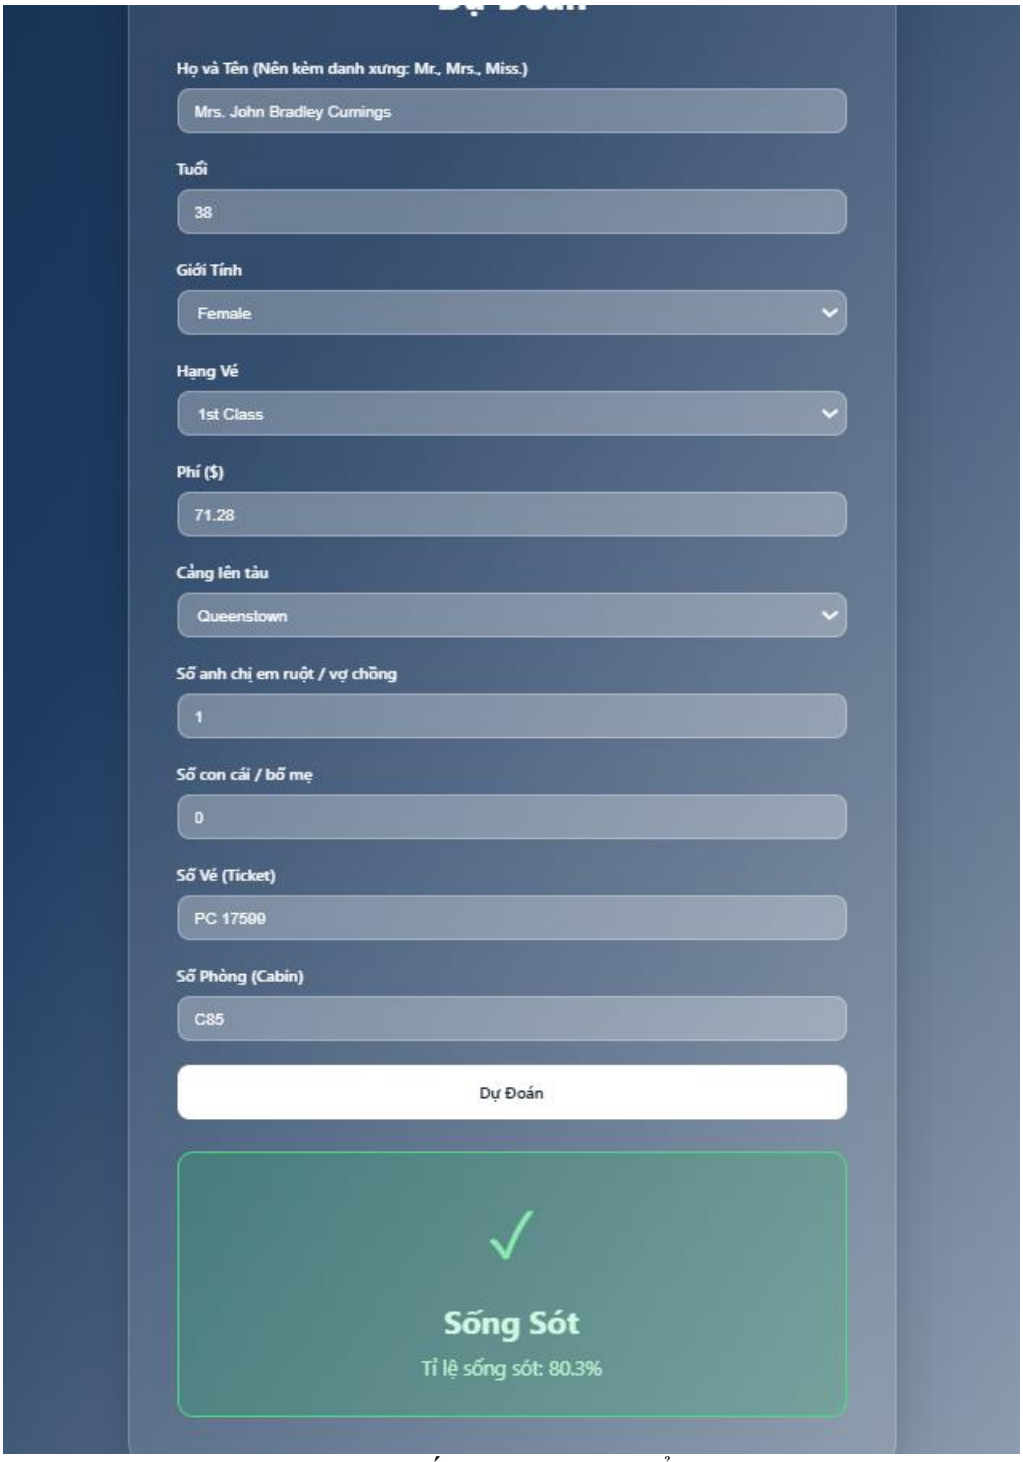


Hình 4 3: Kết quả sau khi triển khai

Dựa trên hình ảnh minh họa, chúng ta thực hiện một thử nghiệm với hành khách thực tế trong lịch sử là Mrs. John Bradley Cumings (một hành khách hạng nhất):

**Dữ liệu đầu vào**

- Tên: Mrs. John Bradley Cumings (Hệ thống trích xuất Title: Mrs)
- Hạng vé: 1st Class
- Phí vé: $71.28

- Cảng lên tàu: Queenstown
- Số phòng: C85 (Hệ thống trích xuất Deck: C, Has_Cabin: 1)

**Kết quả dự báo:**

Sau khi người dùng nhấn nút **"Dự Đoán"**, dữ liệu được gửi về Backend, đi qua Pipeline tiền xử lý và mô hình SVM. Kết quả trả về giao diện như sau:

- **Trạng thái: Sống Sót** (hiển thị bằng màu xanh lá cây và biểu tượng tích v cho cảm giác an toàn).
- **Xác suất dự báo: 80.3%**.

**4.6.. Đánh giá tính logic của giao diện và mô hình:**

Kết quả dự báo 80.3% sống sót cho trường hợp trên là hoàn toàn chính xác với logic của mô hình SVM và dữ liệu lịch sử vì:

- Danh xưng "Mrs" và Giới tính "Female" là hai yếu tố ưu tiên hàng đầu trong quy tắc cứu hộ của Titanic.
- Hạng vé 1 (1st Class) và việc có Số phòng (Cabin) rõ ràng giúp nâng cao vị thế và khả năng tiếp cận thuyền cứu hộ của hành khách trong không gian vector của mô hình SVM.

# CHƯƠNG 5 – KẾT LUẬN & HƯỚNG PHÁT TRIỂN

## 5.1. Tóm tắt kết quả đạt được

Nhóm đã hoàn thành xuyên suốt quy trình end-to-end của dự án ML:

1. EDA toàn diện: Phát hiện Giới tính là đặc trưng quan trọng nhất (nữ 74.2% vs nam 18.9%), theo sau là Hạng vé (Hạng 1: 63% vs Hạng 3: 24.2%). Phân tích đa biến cho thấy Embarked là proxy của Pclass, không phải yếu tố độc lập.
2. Feature Engineering hiệu quả: 7 đặc trưng mới được tạo ra từ dữ liệu gốc, đặc biệt Title (kết hợp giới tính + tuổi + địa vị), FamilySize/Family_Cat (U-shaped relationship với Survived), và Has_Cabin/Deck (địa vị xã hội và vị trí địa lý trên tàu).
3. Pipeline chống Data Leakage: TitanicUnifiedTransformer tích hợp hoàn toàn vào scikit-learn Pipeline, đảm bảo fit chỉ trên train và transform nhất quán.
4. So sánh 3 mô hình qua 5-Fold CV có theo dõi WandB: SVM Poly Kernel (degree=2, C=1) đạt F1-Score 5-fold CV cao nhất (0.7678), được chọn làm model cuối cùng.
5. Triển khai ứng dụng web đầy đủ: FastAPI backend + React frontend, cho phép dự đoán theo thời gian thực với giao diện chủ đề đại dương chuyên nghiệp.

## 5.2. Hạn chế

- Dataset nhỏ (891 mẫu train) có thể hạn chế khả năng tổng quát hóa của mô hình phức tạp.
- Recall chỉ đạt 68.12% – mô hình còn bỏ sót ~32% trường hợp Sống sót thực tế.
- Cột Ticket chưa được khai thác – có thể chứa thông tin về nhóm hành khách đi cùng nhau.
- Cabin thiếu 77.1% – giới hạn chất lượng đặc trưng Deck (chủ yếu là "Unknown").
- Frontend chưa có lịch sử dự đoán, xuất kết quả hay so sánh nhiều hành khách.

## 5.3. Hướng phát triển

- Thử nghiệm XGBoost, LightGBM hoặc Stacking Ensemble để cải thiện Recall và ROC-AUC.

- Áp dụng SMOTE (Synthetic Minority Oversampling Technique) để xử lý mất cân bằng lớp, cải thiện Recall.
- Khai thác Ticket Number – nhóm các hành khách cùng vé để tạo đặc trưng "nhóm đi cùng".
- Thêm Model Explainability bằng SHAP Values – giải thích lý do dự đoán cho từng hành khách.
- Triển khai Docker + Cloud (AWS/GCP) với CI/CD pipeline tự động.
- Mở rộng Frontend: lịch sử dự đoán, biểu đồ xác suất, so sánh nhiều hành khách.

# TÀI LIỆU THAM KHẢO

[1] Kaggle. (2012). Titanic – Machine Learning from Disaster. https://www.kaggle.com/c/titanic

[2] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. JMLR, 12, 2825-2830.

[3] Cortes, C., & Vapnik, V. (1995). Support-vector networks. Machine Learning, 20(3), 273-297.

[4] Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5-32.

[5] Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. JRSS-B, 58(1), 267-288.

[6] FastAPI Documentation. (2024). FastAPI – Modern, Fast Web Framework. https://fastapi.tiangolo.com/

[7] React Documentation. (2024). React – A JavaScript library for building user interfaces. https://react.dev/

[8] Weights & Biases. (2024). WandB – Experiment Tracking. https://wandb.ai/

[9] Géron, A. (2019). Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow (2nd ed.). O'Reilly.

[10] Heaton, J. (2016). An empirical analysis of feature engineering for predictive modeling. SoutheastCon, 1-6.

# PHỤ LỤC

## A. Hướng dẫn cài đặt và chạy

### A.1. Backend

```
$ cd backend
$ pip install -r requirements.txt
$ uvicorn app.main:app --reload --port 8000
# Swagger UI: http://localhost:8000/docs
```

### A.2. Frontend

```
$ cd frontend/titanic-app
$ npm install
$ npm run dev
# Truy cập: http://localhost:5173
```

## B. Ví dụ Request/Response API

### B.1. Request mẫu – POST /predict

```
{
  "PassengerId": 1,
  "Pclass": 1,
  "Name": "Mrs. Margaret Brown",
  "Sex": "female",
  "Age": 44,
  "SibSp": 0,
  "Parch": 0,
  "Ticket": "17770",
  "Fare": 27.7208,
  "Cabin": "B3",
  "Embarked": "C"
}
```

### B.2. Response mẫu

```
{
  "status": "success",
  "prediction": 1,
  "probability_survived": 0.9234
}
```